

一种结合推荐对象间关联关系的社会化推荐算法

郭 磊¹⁾ 马 军¹⁾ 陈竹敏¹⁾ 姜浩然²⁾

¹⁾ (山东大学计算机科学与技术学院 济南 250101)

²⁾ (山东省邮政公司信息技术局 济南 250011)

摘 要 随着社会化媒体的兴起,信息资源的数量呈现爆炸式增长,如何在海量的信息中帮助用户发现有用的知识成为亟需解决的问题. 社会化推荐方法作为一种有效的信息过滤技术,由于能够结合社会网络的特点,模拟现实社会中的推荐过程,在分析用户历史行为的基础上,主动向用户推荐满足他们兴趣和需求的信息,受到了研究者的广泛关注. 但目前已有的方法大都只从用户间社会关系的角度出发,仅认为相互信任的朋友间具有相似的兴趣爱好,而忽略了推荐对象间的关联关系对推荐结果产生的影响. 针对以上存在的问题,文中从推荐对象间关联关系的角度出发,假设具有关联关系的推荐对象更容易受到同一用户的关注,并进而在已有的社会化推荐算法的基础上,提出了一种结合推荐对象间关联关系进行推荐的算法. 算法使用共享的潜在特征空间对目标函数的求解过程进行约束,使其在考虑用户间社会关系的同时,也考虑到推荐对象间关联关系所起到的重要作用. 实验结果表明,与主流的推荐算法相比,文中所提出的方法在分类准确率和评分误差等多种评价指标上都取得了更好的结果.

关键词 社会网络;矩阵分解;推荐系统;协同过滤;社会化推荐

中图法分类号 TP391 DOI号 10.3724/SP.J.1016.2014.00219

Incorporating Item Relations for Social Recommendation

GUO Lei¹⁾ MA Jun¹⁾ CHEN Zhu-Min¹⁾ JIANG Hao-Ran²⁾

¹⁾ (School of Computer Science and Technology, Shandong University, Jinan 250101)

²⁾ (Information Technology Bureau, Shandong Post Company, Jinan 250011)

Abstract With the advent of social media and the exponential growth of information generated by online users, how to help users find useful knowledge from vast amounts of data has become the major problem to be solved. Social recommendation method as one of the effective information filtering techniques attempting to provide active suggestions with social networks has been well studied. Most of these methods assume trusted friends have similar interests. Typically, they simulate the recommendation process in real social networks to automatically predict the user's preference by collecting the history behaviors and ratings from his/her friends. However, these methods only consider the influence of social networks from users' perspective, and assume items are independent and identically distributed. This assumption ignores the fact that item relations can be important factors in many recommendation scenarios. Aiming at solving the above problem, based on the intuition that related items will be probably selected by the same user, we propose a novel social recommendation method and incorporate item relations using a probabilistic matrix factorization framework from the items' perspective. Specifically, our method utilizes the shared latent feature space to constrain the objective function, and considers the influence of user

收稿日期:2012-10-25;最终修改稿收到日期:2013-07-06. 本课题得到国家自然科学基金(61272240,60970047,61103151)、教育部博士点基金(20110131110028)、山东省自然科学基金(ZR2012FM037)、山东省优秀中青年科学家科研奖励基金(BS2012DX017)资助. 郭 磊,男,1983年生,博士研究生,中国计算机学会(CCF)会员,主要研究方向为信息检索、社会网络和推荐系统. E-mail: guolei@rocketmail.com. 马 军,男,1956年生,博士,教授,博士生导师,主要研究领域为信息检索、数据挖掘、并行计算和自然语言处理. E-mail: majun@sdu.edu.cn. 陈竹敏,男,1977年生,博士,副教授,主要研究方向为信息检索、数据挖掘和社会计算. 姜浩然,女,1986年生,硕士,主要研究方向为网络计算和社会计算.

connections and item relations simultaneously. Experimental results in real world social network show that the proposed approach outperforms state-of-the-art recommendation algorithms in terms of precision and rating error.

Keywords social networks; matrix factorization; recommender system; collaborative filtering; social recommendation

1 引 言

近年来,随着诸如 Facebook、Twitter 等社会化媒体的兴起,利用用户间的社会关系进行推荐的方法,由于能更好地模拟现实社会中的推荐过程,更能体现出人在推荐过程中的作用,逐渐成为推荐领域的研究热点.例如, Ma 等人^[1-2]研究了如何利用用户间的社会关系来进一步提高传统推荐方法的性能,并给出了一种能够将社会关系信息进行整合的概率矩阵分解框架. Jamali 等人^[3]则通过对用户间信任关系的传播现象进行建模,提出了一种基于信任传播的推荐方法.

以上这些社会化推荐方法,虽然能够对推荐的社会化过程进行建模,但它们大都只从用户的角度出发,而假设推荐对象之间是相互独立的,忽略了推荐对象间的关联关系在许多应用场景中对推荐结果产生的影响.例如,在微博中的 Follow 关系推荐场景中,当我们为用户推荐 Follow 关系时,用户往往更倾向于选择那些与自己的朋友有 Follow 关系的人(推荐对象之间存在 Follow 关系).再比如,在商品推荐场景中,用户则更倾向于选择那些与自己购买过的商品有关联关系的物品(曾经购买过羽毛球拍的用户,很有可能会在未来购买羽毛球).

基于对以上应用场景的分析,为了能更好地对推荐过程进行建模,从而体现出推荐对象间的关联关系对推荐结果产生的影响.在本文中,我们首先引入了在 Netflix Prize^① 比赛中取得较好成绩的矩阵分解方法对用户的评分信息进行建模,然后在已有社会化推荐算法的基础上融入了推荐对象间的关联关系信息进行推荐.具体而言,我们将三种不同类型的数据信息(用户间的社会关系、对象间的关联关系和评分信息)通过共享的潜在特征空间进行关联,使得算法在学习过程中能对目标函数进行约束,从而达到优化推荐结果的目的.

本文的贡献主要包括以下 3 个方面:(1)在已有社会化推荐算法的基础上提出了一种结合推荐对

象间关联关系的推荐方法,并给出了算法的概率图模型和具体的求解过程;(2)使用共享特征空间的方法利用社会网络信息对推荐结果进行优化,将 3 种不同类型的信息关联到一个统一的推荐框架中;(3)在微博数据集上测试了算法在准确率和评分误差等评价指标上的性能,分析了推荐对象间的关联关系和算法中的参数对实验结果的影响.

2 相关工作

这一节主要介绍了与本文相关的几种社会化推荐算法和本文所研究内容的最新进展.

推荐系统按照所使用的数据来分类^[4],可以分为协同过滤^[5-6]、内容过滤^[7-8]和社会化推荐系统等.其中,社会化推荐系统是指利用了用户或推荐对象间的社会网络信息对推荐过程进行建模的算法.这里的社会网络信息主要包括用户间的信任或朋友关系,以及推荐对象间的关联关系.其中用户间的信任或朋友关系是指用户间由于有共同的兴趣爱好而形成的一种社会关系.

目前,社会化推荐算法大都集中在如何利用用户间的社会关系来提高推荐的准确率.例如,在文献^[9-10]中, Massa 和 Avesani 研究了利用信任关系来改进协同过滤的方法,他们在算法中使用用户间的信任关系矩阵来代替寻找相似用户的过程,并且假设这种信任关系不但可以在信任网络中进行传播,还可以对未知的信任值进行预测.实验结果表明,他们的方法可以在不降低正确率的情况下,有效地提高覆盖率.在文献^[11]中, Ma 等人提出了一种基于矩阵分解的社会化推荐方法,他们通过一个共享的低维潜在用户特征矩阵,将用户间的信任关系网络同评分矩阵结合在一起.实验结果表明,与传统的推荐方法相比,他们的方法能取得更好的推荐效果.在随后的工作中^[1],他们又从解决数据稀疏性的角度出发,将用户及其朋友的兴趣信息使用统一的

① <http://www.netflixprize.com/>

框架进行整合,同时利用用户评分和用户间的信任关系信息进行推荐. Konstantas 等人^[12]则通过在音乐推荐系统中使用带重启的随机游走模型对朋友关系和标注关系进行建模,研究了社交网络在推荐系统中的作用.

另外一些相关工作则围绕着如何挖掘更深层次的用户关系信息来提高推荐的质量,如 Yuan 等人^[13]研究了社会网络中的两种社交关系“friendship”和“membership”在推荐系统中的作用,并提出了一种将它们融合在一起的推荐算法. Yang 等人在文献^[14]中认为用户间的信任关系强度并不是唯一的,而是受到其所处的朋友圈的影响,在不同的朋友圈中,用户间的信任关系也是不同的. 他们通过给用户的朋友赋予不同的权重来对用户间的信任关系进行建模,并提出了一种基于朋友圈的社会化推荐算法. Noel 等人^[15]针对社会化推荐算法在计算用户相似性时没有考虑到用户本身的特征、不能直接对用户间信息传播建模和不能反映用户间只有部分兴趣相同的问题,给出了一种将多种目标函数整合在一起的方法,并在矩阵分解的框架下进行求解.

已有的社会化推荐算法虽然取得了不错的推荐效果,但它们大都只从用户间社会关系的角度出发,而忽略了推荐对象间关联关系的重要性. 因此本文从推荐对象间关联关系的角度出发,研究了其对推荐结果所产生的影响. 目前,在社会网络中结合推荐对象间的关联关系进行推荐的相关研究还较少. 例如, Jiang 等人^[16]在研究为用户推荐 tweets 的工作中,提出了一种基于社会上下文信息的推荐算法,并使用推荐对象间的内容相似性对目标函数进行约束,但是该方法并没有考虑推荐对象间显示的关联关系,他们的工作更侧重于如何对不同的社会上下文信息进行建模. Liu 等人^[17]利用推荐对象的属性上下文信息来对它们之间的关联关系进行度量,并通过估计出的关联关系信息来改善推荐的效果. 但是他们的工作主要集中在如何从上下文信息中推导出隐式的关联关系信息,并且也没有进一步将所推导出的关联关系同用户间的社会关系融合在一起.

3 推荐方法

在这一部分,我们首先以微博中的 Follow 关系推荐为例对问题进行说明,然后引入基于概率矩阵分解的方法对评分信息进行建模;接着,我们又以

SoRec^[11]算法为例,介绍了利用用户间的社会关系信息进行推荐的方法,最后我们在 SoRec 算法的基础上提出了一种结合推荐对象间关联关系的社会化推荐算法.

3.1 问题描述

我们以微博中的 Follow 关系推荐场景为例对问题进行说明. 在微博中,用户通过与其他用户之间建立 Follow 关系,来获取其发布的信息,并且这种 Follow 关系是单向的,不需要得到目标用户的认可. Follow 关系推荐就是通过分析用户的社交网络结构和历史评分信息,帮助他们建立合适的 Follow 关系,这里的评分信息是指用户对推荐结果的历史选择情况. 图 1 展示了在微博中进行 Follow 关系推荐的场景,从图 1 中可以看出,这一场景主要包括 3 个核心要素:(1)用户之间的 Follow 关系,(2)推荐对象之间的 Follow 关系,(3)用户对推荐对象的评分信息.




图 1 微博中的 Follow 关系推荐示例

图 1(a)定义了用户和推荐对象间的 Follow 关系图 $G=(U \cup V, E)$, 其中 U, V 分别表示用户和推荐对象的集合; $\forall u_1, u_2 \in U, (u_1, u_2) \in E$ 表示用户 u_1 Follow u_2 ; $\forall v_1, v_2 \in V, (v_1, v_2) \in E$ 表示对象 v_1 与 v_2 之间存在 Follow 关系; $\forall u \in U, \forall v \in V, (u, v) \in E$ 表示将对象 v 推荐给用户 u ; 图 1(b)定义了用户的评分矩阵 $R=U \times V$; 其中, $\forall u \in U, \forall v \in V, R(u, v)=1$ 表示 u 喜欢 $v, R(u, v)=0$ 表示不喜欢; $R(u, v)=?$ 表示没有相应的评分记录. 在这样一个二值推荐问题中,我们的目标就是利用所观察到的社交网络和历史评分信息去预测评分矩阵中的缺失项(0 或 1),从而判断用户最终是否会选择某个推荐对象.

3.2 基于评分的推荐方法

为了有效地对评分信息进行建模,在论文中我们引入了概率矩阵分解方法^[18] (Probabilistic Matrix Factorization, PMF)作为基本的推荐框架.

PMF 方法通过对用户的评分矩阵进行分解,来推导出两个分别表示用户和推荐对象的低维潜在特征矩阵,而这些特征是刻画用户和推荐对象的关键因素.另外,由于 PMF 方法在学习过程中只需要使用较低维度的特征向量,使得它的计算复杂度较低,在社会网络这样大规模的数据集上具有较高的可扩展性和准确性.

假设用户的评分矩阵 R 中有 m 个用户, n 个推荐对象,其中 $r_{ij} \in [0, 1]$ 表示用户 u_i 对推荐对象 v_j 的评分. $U \in \mathbf{R}^{l \times m}$ 和 $V \in \mathbf{R}^{l \times n}$ 分别表示分解得到的与用户和推荐对象相关的 l -维特征矩阵,其列向量 U_i 和 V_j 则分别表示相对应的潜在特征向量.由于 PMF 假设可观测评分是由概率线性模型 $U_i V_j$ 和高斯观测噪声组成的,因此评分矩阵 R 的条件概率分布可以定义为^[19]

$$p(R|U, V, \sigma_R^2) = \prod_{i=1}^m \prod_{j=1}^n [N(r_{ij} | g(U_i^T V_j), \sigma_R^2)]^{I_{ij}^R} \quad (1)$$

其中, $N(x | \mu, \sigma^2)$ 表示 x 服从均值为 μ , 方差为 σ^2 的高斯分布, I_{ij}^R 是指示函数,它表示如果用户 u_i 对推荐对象 v_j 进行了评分,它的值就等于 1, 否则为 0. 函数 $g(x)$ 表示逻辑函数 $g(x) = 1/(1 + \exp(-x))$, 使用它的目的是将预测值 $(U_i^T V_j)$ 限定在区间 $[0, 1]$ 之内. 假设 U 和 V 同样服从均值为 0 的球形高斯先验^[20]:

$$\begin{aligned} p(U | \sigma_U^2) &= \prod_{i=1}^m N(U_i | 0, \sigma_U^2 I), \\ p(V | \sigma_V^2) &= \prod_{j=1}^n N(V_j | 0, \sigma_V^2 I) \end{aligned} \quad (2)$$

经过贝叶斯推断,可以得到 U 和 V 的联合后验概率分布^[18]:

$$\begin{aligned} p(U, V | R, \sigma_R^2, \sigma_U^2, \sigma_V^2) &\propto p(R | U, V, \sigma_R^2) p(U | \sigma_U^2) p(V | \sigma_V^2) \\ &= \prod_{i=1}^m \prod_{j=1}^n [N(r_{ij} | g(U_i^T V_j), \sigma_R^2)]^{I_{ij}^R} \times \\ &\quad \prod_{i=1}^m N(U_i | 0, \sigma_U^2 I) \times \prod_{j=1}^n N(V_j | 0, \sigma_V^2 I) \end{aligned} \quad (3)$$

如式(3)所示, PMF 方法只利用了用户的评分矩阵信息对用户和推荐对象的潜在特征进行估计,而没有考虑到用户间的社会关系以及推荐对象间的关联关系,推荐的准确率还有待进一步提高. 在接下来的章节中,我们首先引入了 SoRec 方法,介绍如何利用用户间的社会关系信息来为目标用户进行推荐.

3.3 SoRec 方法

假设用户间的社会关系网络用图 $G' = (U, E')$ 表示,其中 $U = \{u_i\}_{i=1}^m$ 表示用户的集合, E' 表示用户间的社会关系. $D = \{d_{ij}\}$ 表示图 G' 的社会关系矩阵^① ($m \times m$), 对于任意一对用户 u_i 和 u_j 来说,如果他们之间存在社会关系,则用 $d_{ij} \in (0, 1]$ 表示所对应的有向边 u_i 到 u_j 的权重, 否则 $d_{ij} = 0$. 有向边的权重 d_{ij} 代表了在社会网络中 u_i 对 u_j 的信任程度或熟知程度.

Ma 等人提出的 SoRec 方法假设社会关系矩阵 D 表征了用户在社会网络中的重要交互信息,通过对其进行分解可以学习到表示用户社交行为的低维潜在重要特征. $U \in \mathbf{R}^{l \times m}$ 和 $Q \in \mathbf{R}^{l \times m}$ 表示分解之后与用户相关的特征矩阵,列向量 U_i 和 Q_k 分别表示与它们相对应的潜在特征向量. 矩阵 D 的条件概率分布定义为

$$p(D | U, Q, \sigma_D^2) = \prod_{i=1}^m \prod_{k=1}^m [N(d_{ik} | g(U_i^T Q_k), \sigma_D^2)]^{I_{ik}^D} \quad (4)$$

其中 I_{ik}^D 是指示函数,它表示当用户之间存在直接的社会关系时,其值取 1, 否则为 0. 假设 U, Q 服从均值为 0 的球形高斯先验:

$$\begin{aligned} p(U | \sigma_U^2) &= \prod_{i=1}^m N(U_i | 0, \sigma_U^2 I), \\ p(Q | \sigma_Q^2) &= \prod_{k=1}^m N(Q_k | 0, \sigma_Q^2 I) \end{aligned} \quad (5)$$

为了分析用户间的社会关系是否会影响用户的决策过程, SoRec 方法使用共享的用户特征空间将用户间的社会关系与评分信息结合在一起,通过对这两部分信息进行联合分解,识别出在评分上比较相近并且具有社会关系的用户来进行推荐,使用的概率图模型如图 2 所示. U, V 和 Q 的联合后验概率分布可以表示为^[9]

$$\begin{aligned} p(U, V, Q | R, D, \sigma_R^2, \sigma_D^2, \sigma_U^2, \sigma_V^2, \sigma_Q^2) &\propto p(R | U, V, \sigma_R^2) p(D | U, Q, \sigma_D^2) \times \\ &\quad p(U | \sigma_U^2) p(V | \sigma_V^2) p(Q | \sigma_Q^2) \\ &= \prod_{i=1}^m \prod_{j=1}^n [N(r_{ij} | g(U_i^T V_j), \sigma_R^2)]^{I_{ij}^R} \times \\ &\quad \prod_{i=1}^m \prod_{k=1}^m [N(d_{ik} | g(U_i^T Q_k), \sigma_D^2)]^{I_{ik}^D} \times \\ &\quad \prod_{i=1}^m N(U_i | 0, \sigma_U^2 I) \times \prod_{j=1}^n N(V_j | 0, \sigma_V^2 I) \times \end{aligned}$$

① 这里的社会关系矩阵表示的是图 G' 的邻接矩阵.




图 2 SoRec 的概率图模型

3.4 结合推荐对象间关联关系的推荐方法

SoRec 方法通过对用户间的社会关系矩阵进行分解来学习用户的潜在特征,通过共享的特征空间来约束求解的过程,从而达到使用朋友的兴趣信息进行推荐的目的.但是,这种方法只是从用户的角度出发,而认为推荐对象间是相互独立的,没有考虑到对象间的关联关系同样也是影响用户决策的重要因素.

为了研究推荐对象间的关联关系对推荐结果产生的影响以及如何利用这部分信息来进一步提高推荐算法的性能,我们在 SoRec 方法的基础上提出了一种结合推荐对象间关联关系的社会化推荐方法 (Probabilistic Matrix Factorization with User and Item relations, PMFUI).

假设推荐对象间的关联关系用图 $G^* = (V, E^*)$ 表示,其中 $V = \{v_i\}_{i=1}^n$ 表示推荐对象的集合, E^* 表示推荐对象间的关联关系. $S = \{s_{ij}\}$ 表示图 G^* 的关联关系矩阵^① ($n \times n$),对于任意两个推荐对象 v_i 和 v_j 来说,如果它们之间存在关联关系,则用 $s_{ij} \in (0, 1]$ 表示所对应有向边的权重,否则 $s_{ij} = 0$. 权重 s_{ij} 的大小代表了推荐对象 v_i 和 v_j 之间的关联程度.

在社会网络中,关联关系的紧密程度可以通过对象间链接关系的网络结构进行刻画^[21].例如在朋友推荐中,如果被推荐的朋友之间存在直接相连的链接关系,则表明他们很可能处于一个较为紧密的朋友圈中.在本文中,我们使用较为流行的 PropFlow 方法^[22]对 s_{ij} 的值进行计算. PropFlow 方法使用对象间信息流的大小,对它们在网络上的链接关系进行估算,信息流越大,表明对象间的链接关系越紧密.

通过对关联关系矩阵 S 进行分解,可以学习到表示推荐对象之间关联关系的低维潜在特征矩阵.

推荐对象 v_i 和 v_j 在图 G^* 上的关联关系信息 s_{ij} ,是求解它们的特征向量 V_i 和 V_j 的重要信息来源^②,关联关系矩阵 S 的后验概率分布可以定义为

$$p(S | V, \sigma_s^2) = \prod_{i=1}^n \prod_{j=1}^n [N(s_{ij} | g(V_i^T V_j), \sigma_s^2)]^{I_{ij}^s} \quad (7)$$

其中,指示函数 I_{ij}^s 表示如果 v_i 和 v_j 在图 G^* 上有直接的链接关系,其值为 1,否则为 0. 我们假设 V 服从均值为 0 的球形高斯先验(参见式(2)).

为了利用推荐对象间的关联关系对求解的过程进行优化,我们通过共享的潜在特征空间将推荐对象间的关联关系、用户间的社会关系和评分信息结合在一起,通过发现社会网络中相互关联的推荐对象来进一步提高推荐的效果.所使用的概率图模型如图 3 所示, U, V, Q 的对数联合后验概率分布可以进一步表示为

$$\begin{aligned} \ln p(U, V, Q | R, D, S, \sigma_r^2, \sigma_u^2, \sigma_s^2, \sigma_v^2, \sigma_q^2) = & -\frac{1}{2\sigma_r^2} \sum_{i=1}^m \sum_{j=1}^n I_{ij}^r (r_{ij} - g(U_i^T V_j))^2 - \\ & \frac{1}{2\sigma_d^2} \sum_{i=1}^m \sum_{k=1}^m I_{ik}^d (d_{ik} - g(U_i^T Q_k))^2 - \\ & \frac{1}{2\sigma_s^2} \sum_{i=1}^n \sum_{j=1}^n I_{ij}^s (s_{ij} - g(V_i^T V_j))^2 - \\ & \frac{1}{2\sigma_u^2} \sum_{i=1}^m U_i^T U_i - \frac{1}{2\sigma_v^2} \sum_{j=1}^n V_j^T V_j - \\ & \frac{1}{2\sigma_q^2} \sum_{k=1}^m Q_k^T Q_k - \frac{1}{2} \left(\sum_{i=1}^m \sum_{j=1}^n I_{ij}^r \right) \ln \sigma_r^2 - \\ & \frac{1}{2} \left(\left(\sum_{i=1}^m \sum_{k=1}^m I_{ik}^d \right) \ln \sigma_d^2 + \left(\sum_{i=1}^n \sum_{j=1}^n I_{ij}^s \right) \ln \sigma_s^2 \right) - \\ & \frac{1}{2} (ml \ln \sigma_u^2 + nl \ln \sigma_v^2 + ml \ln \sigma_q^2) + C \end{aligned} \quad (8)$$

其中, C 是不依赖于参数的常量,求参数固定时 U, V, Q 的极大后验概率,相当于最小化以下带正则项的误差平方和函数:

$$\begin{aligned} E(R, D, S, U, V, Q) = & \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^n I_{ij}^r (r_{ij} - g(U_i^T V_j))^2 + \\ & \frac{\lambda_d}{2} \sum_{i=1}^m \sum_{k=1}^m I_{ik}^d (d_{ik} - g(U_i^T Q_k))^2 + \\ & \frac{\lambda_s}{2} \sum_{i=1}^n \sum_{j=1}^n I_{ij}^s (s_{ij} - g(V_i^T V_j))^2 + \\ & \frac{\lambda_u}{2} \|U\|_F^2 + \frac{\lambda_v}{2} \|V\|_F^2 + \frac{\lambda_q}{2} \|Q\|_F^2 \end{aligned} \quad (9)$$

① 在本文中我们使用关联关系矩阵表示图 G^* 的邻接矩阵.

② 在本文中,我们使用 V 表示与对推荐对象有关的特征矩阵,并使用 V 的不同分量 V_i 和 V_j 表示对关联关系矩阵分解之后的特征向量.

其中, $\lambda_D = \sigma_R^2 / \sigma_D^2$, $\lambda_S = \sigma_R^2 / \sigma_S^2$, $\lambda_U = \sigma_R^2 / \sigma_U^2$, $\lambda_V = \sigma_R^2 / \sigma_V^2$, $\lambda_Q = \sigma_R^2 / \sigma_Q^2$, $\|\cdot\|_F$ 表示 Frobenius 范数. 对于式(9)所示的目标函数, 我们通过 U, V 和 Q 上使用梯度下降的方法进行求解, 使其达到局部极小值:

$$\begin{aligned} \frac{\partial E}{\partial U_i} &= \sum_{j=1}^n I_{ij}^R g'(U_i^T V_j) (g(U_i^T V_j) - r_{ij}) V_j + \\ &\quad \lambda_D \sum_{k=1}^m I_{ik}^D g'(U_i^T Q_k) (g(U_i^T Q_k) - d_{ik}) Q_k + \lambda_U U_i, \\ \frac{\partial E}{\partial V_j} &= \sum_{i=1}^n I_{ij}^R g'(U_i^T V_j) (g(U_i^T V_j) - r_{ij}) U_i + \\ &\quad \lambda_S \sum_{t=1}^n I_{tj}^S g'(V_t^T V_j) (g(V_t^T V_j) - s_{tj}) V_t + \lambda_V V_j, \\ \frac{\partial E}{\partial Q_k} &= \lambda_D \sum_{i=1}^n I_{ik}^D g'(U_i^T Q_k) (g(U_i^T Q_k) - d_{ik}) U_i + \lambda_Q Q_k \end{aligned} \quad (10)$$

其中, $g'(x) = \exp(x) / (1 + \exp(x))^2$ 是回归函数 $g(x)$ 的导数.




图3 PMFUI的概率图模型

4 实验结果与分析

在这一部分, 我们首先通过几组实验对比了本文的方法与已有方法在推荐效果上的差异, 然后进一步分析了 PMFUI 方法中实验参数和关联关系的计算方法对实验结果的影响.

4.1 数据集

在实验中, 我们采用了 KDD CUP 在 2012 年发布的数据集^①, 该数据集记录了腾讯微博在某个时间段内微博用户对某些推荐对象的评分信息(是否会选择某个对象). 这些推荐对象既可以是人, 也可以是某个社团或组织. 其中, 推荐对象间的关联关系是指它们在微博中的 Follow 关系, 表示两个推荐对象之间是否相互关注. 为了更好地突出问题本身, 降低模型的计算复杂度, 我们只抽取了该数据集中的评分信息、用户间的社会关系信息和推荐对象间的关联关系信息作为主要的数据来源(原数据集中还

包括内容、分类和标签等更加丰富的信息). 在新提取的数据集中, 共涉及到了 50 万个用户、6000 个推荐对象、21803721 条训练数据和 100 万条测试样例以及 287381 条用户间的社会关系信息和 170080 条推荐对象之间的关联关系信息.

4.2 评价方法

我们采用了较为常用的 RMSE、MAE、precision、recall、F₁-measure 和 MAP 等 6 种指标^[23-24] 去评价推荐结果的好坏. RMSE 和 MAE 是评价预测评分准确性的标准, 它们反映的是算法的预测评分与用户实际评分的贴近程度. 其中, MAE 的定义为 $MAE = \frac{1}{T} \sum_{i,j} |R_{ij} - \hat{R}_{ij}|$, R_{ij} 表示用户 u_i 对推荐对象 v_j 的实际评分, \hat{R}_{ij} 则表示相应的预测评分, T 表示测试样例的数量. 与 MAE 的定义类似, RMSE 的公式可以表示为 $RMSE = \sqrt{\frac{1}{T} \sum_{i,j} (R_{ij} - \hat{R}_{ij})^2}$, 并且 MAE 和 RMSE 的值越小, 表示系统的推荐效果越好.

另外一类评价指标, 如 precision、recall、F₁-measure 和 MAP 等是对推荐算法分类准确率进行度量的标准, 反映的是推荐系统对分类预测的准确程度, 它们特别适合于具有明确二分喜好的用户系统.

其中, precision 的定义为 $precision = \frac{1}{T} \sum_u N_{tp} / L$, N_{tp} 表示推荐列表中用户所喜欢的推荐对象的数量, L 表示推荐列表的长度. recall 的定义为 $recall = \frac{1}{T} \sum_u N_{tp} / B_u$, 其中, B_u 表示测试集中用户 u 所喜欢的推荐对象的数量, 它表达的是用户所喜欢的推荐对象能被推荐的概率. 这样, 可以将 F₁-measure 定义为 $F_1 = (2 \times precision \times recall) / (precision + recall)$, 该测度由于同时考虑了 precision 和 recall 的值, 因此能较为全面地评价算法的优劣. 另外一个评价分类准确率的指标是 MAP, 它的定义为 $MAP = \frac{1}{T} \sum_{j=1}^T (\sum_{k=1}^L P(L_{jk}) / m_j)$, m_j 表示在第 j 次推荐中用户所喜欢的推荐对象的数量, $P(L_{jk})$ 表示第 j 次推荐中推荐列表前 k 个位置中用户所喜欢的推荐对象的数量与位置 k 的比值, L 是推荐列表的长表, 在实验中我们取 $L=5$.

4.3 结果比较

为了验证推荐对象间的关联关系和用户间的社会关系在推荐过程中所起到的作用以及它们对

① <http://www.kddcup2012.org/c/kddcup2012-track1/data>

推荐结果产生的影响,在实验中我们比较了 PMF、SoRec、PMFUI 和两种基于记忆类型的方法 ItemMean 和 ItemKNN^[25] 在未知数据上的推荐效果. 在 PMFUI 中我们首先使用 PropFlow 作为推荐对象间关联关系的计算方法.

实验中的参数设置如下: $\lambda_D=10$, $\lambda_U=\lambda_V=\lambda_Q=0.01$, 并且在所有的实验中,算法的最大迭代次数设为 100. 表 1 给出了在 $\lambda_s=5$, 潜在特征向量的维度分别为 10 和 15 的情况下的实验结果. 从表 1 中我们可以看出,在这两种不同的维度下,PMFUI 方法在分类准确率和评分误差率指标上都取得了较好的结果(结果要优于 SoRec 和 PMF 两种方法). 这个结果表明,经常被忽视的推荐对象间的关联关系信息,是推荐过程中的重要因素,它与用户间的社会关系信息一样,能对推荐的最终结果产生重要影响. 另外,从表 1 中我们还可以看出,基于矩阵分解的算法与两种基于记忆类型的算法(ItemMean 和 ItemKNN)相比,推荐结果在 MAE 和 RMSE 等评价指标上都有明显的提高,这也证明了矩阵分解方

法的有效性.

表 1 实验结果比较($\lambda_s=5, L=5$)

方法	维度=10					
	precision	recall	F_1 -measure	MAP	MAE	RMSE
ItemMean	0.0885	0.2996	0.1368	0.2148	0.5589	0.5377
ItemKNN	0.0893	0.3051	0.1381	0.2191	0.4462	0.4782
PMF	0.0897	0.3067	0.1388	0.2206	0.4455	0.4700
SoRec	0.0950	0.3242	0.1469	0.2402	0.4418	0.4757
PMFUI	0.0957	0.3259	0.1480	0.2418	0.4377	0.4671

方法	维度=15					
	precision	recall	F_1 -measure	MAP	MAE	RMSE
ItemMean	0.0885	0.2996	0.1368	0.2148	0.5589	0.5377
ItemKNN	0.0893	0.3051	0.1381	0.2191	0.4462	0.4782
PMF	0.0903	0.3084	0.1397	0.2229	0.4456	0.4701
SoRec	0.0946	0.3241	0.1465	0.2402	0.4413	0.4784
PMFUI	0.0953	0.3247	0.1474	0.2417	0.4362	0.4678

图 4 给出了推荐结果随推荐列表长度的变化情况. 从图中可以看出, *precision* 和 *recall* 受列表长度的影响较为明显, 而 F_1 -measure 和 MAP 所受的影响则相对较小. 该图同样表明, PMFUI 方法在不同的推荐列表长度下都能取得较好的结果.

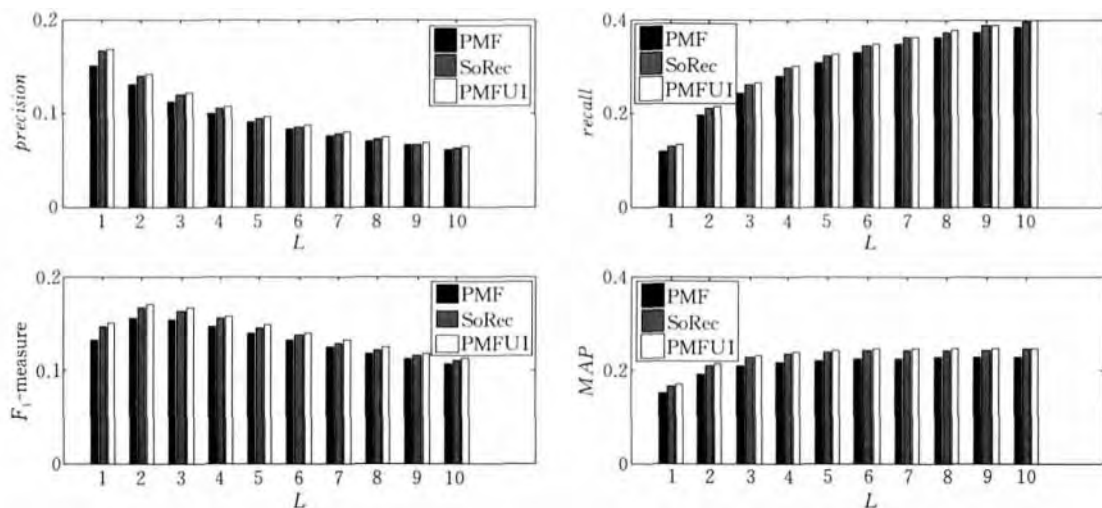



图 4 推荐结果随列表长度的变化情况

4.4 参数的影响

在 PMFUI 方法中, 参数 λ_s 起到了很重要的作用, 它控制了推荐对象间的关联关系信息在整个推荐过程中所占的比重, 也就是推荐方法对这部分信息的依赖程度. 当 $\lambda_s=0$ 时, 该方法将会只使用用户间的社会关系及评分信息作为推荐的依据; 当 $\lambda_s \rightarrow \infty$ 时, 该方法仅使用推荐对象间的关联关系信息进行推荐; 在其它情况下, 该方法则综合使用了评分信息、用户间的社会关系以及推荐对象间的关联关系三部分信息作为推荐的依据.

图 5 给出了 λ_s 对各个评价指标的影响, 我们发

现 λ_s 的取值对实验结果有较为显著的影响, 随着 λ_s 取值的不同, 推荐的结果也发生了很大的变化. 当 λ_s 从 0 开始增加时, MAE 和 RMSE 的值逐渐降低 (越低越好), 但是当 λ_s 超过某个阈值之后, MAE 和 RMSE 开始逐渐增大. 而分类正确率指标 *precision*、*recall* 和 F_1 -measure 则首先随着 λ_s 的增加而增加 (越大越好), 然后当 λ_s 达到阈值以后, 开始逐渐减小. 推荐结果随着参数 λ_s 的波动情况, 也正好反映了推荐对象间的关联关系对推荐过程产生的影响, 推荐对象间的关联关系在推荐算法中所占的比重, 直接影响了最终推荐的质量.

图 5 参数 λ_s 对实验结果的影响(维度=10)

4.5 关联关系计算方法的比较

在 PMFUI 中,关联关系的大小反应了推荐对象间相互关联的紧密程度,它是用户选择推荐对象的重要依据.在本文中,我们进一步比较了 PropFlow 方法与 Katz 方法^[21]在推荐效果上的差异.另外,为了验证它们对推荐算法的贡献程度,我们还同时比较了关联关系取两种特殊值的情况:(1)关联关系矩阵全为 1,它表示将推荐对象间的关联关系都统一对待;(2)关联关系矩阵为 $[0,1]$ 之间的随机生成数.

实验结果如表 2 所示,其中,PMFUI_1 表示推荐对象间的关联关系取值为 1,PMFUI_R 表示推荐对象间的关联关系为随机值,PMFUI_K 和 PMFUI_P 则表示分别用 Katz 和 PropFlow 方法进行计算.其中,PMFUI_P 方法在 *precision*、*recall*、*F₁-measure* 和 *RMSE* 等指标上都取得了最好的推荐结果,而 PMFUI_K 方法则在 *MAP* 和 *MAE* 两种指标上取得了较好的结果.从表 2 中还可以看出,关联关系在两种特殊取值的情况下都不如使用 Katz 和 PropFlow 方法计算得到的结果.这也意味着,关联关系的取值直接影响了推荐方法的最终结果,并且我们既不能将它去掉也不能简单地用随机数来代替.

表 2 关联关系计算方法的比较($\lambda_s=5, L=5$)

方法	评价指标					
	<i>precision</i>	<i>recall</i>	<i>F₁-measure</i>	<i>MAP</i>	<i>MAE</i>	<i>RMSE</i>
PMFUI_R	0.0946	0.3243	0.1465	0.2233	0.4424	0.4769
PMFUI_1	0.0952	0.3244	0.1472	0.2406	0.4441	0.4760
PMFUI_K	0.0956	0.3254	0.1478	0.2419	0.4376	0.4671
PMFUI_P	0.0957	0.3259	0.1480	0.2418	0.4377	0.4671

5 结论和工作展望

本文提出了一种结合推荐对象间关联关系的推

荐方法,该方法在推荐过程中考虑了推荐对象的关联关系、用户间的社会关系以及评分矩阵三部分信息,并给出了一种将它们结合在一起的推荐框架.实验结果表明,推荐对象间的关联关系在推荐过程中起到了重要作用,是用户选择推荐结果的重要依据之一.另外,该方法虽然是在社会网络的环境下提出的,但是当上下文信息发生变化时,我们只需要调整关联关系的计算方法,就可以很容易地将其扩展到其它应用场景中.

为了突出问题本身,本文只考虑了社会网络的结构信息,而忽略了用户与推荐对象的其它上下文信息对推荐结果的影响,如用户的位置、发布的 tweets 和人口统计属性等.在未来的工作中,我们打算研究如何将更多的上下文信息加入到推荐方法中,以便进一步改善推荐的效果.

参 考 文 献

- [1] Ma H, King I, Lyu M. Learning to recommend with social trust ensemble//Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. Boston, USA, 2009: 203-210
- [2] Ma H, Zhou D, Liu C, et al. Recommender systems with social regularization//Proceedings of the 4th ACM International Conference on Web Search and Data Mining. Hong Kong, China, 2011: 287-296
- [3] Jamali M, Ester M. A matrix factorization technique with trust propagation for recommendation in social networks//Proceedings of the 4th ACM Conference on Recommender Systems. Barcelona, Spain, 2010: 135-142
- [4] Xiang Liang. Recommendation in Practice. Beijing: Posts & Telecom Press, 2012(in Chinese)
(项亮. 推荐系统实践. 北京: 人民邮电出版社, 2012)
- [5] Bell R, Koren Y, Volinsky C. Modeling relationships at multiple scales to improve accuracy of large recommender

- systems//Proceedings of the 13th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. San Jose, USA, 2007: 95-104
- [6] Onuma K, Tong H, Faloutsos C. Tangent: A novel', surprise me', recommendation algorithm//Proceedings of the 15th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. Paris, France, 2009: 657-666
- [7] Musto C. Enhanced vector space models for content-based recommender systems//Proceedings of the 4th ACM Conference on Recommender Systems. Barcelona, Spain, 2010: 361-364
- [8] Song Y, Zhuang Z, Li H, et al. Real-time automatic tag recommendation //Proceedings of the 31st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval. Singapore, 2008: 515-522
- [9] Massa P, Avesani P. Trust-aware collaborative filtering for recommender systems//Meersman R, Tari Z eds. On the Move to Meaningful Internet Systems 2004: CoopIS, DOA, and ODBASE. Italy: Springer Berlin Heidelberg, 2004: 492-508
- [10] Massa P, Avesani P. Trust-aware recommender systems//Proceedings of the 2007 ACM Conference on Recommender Systems. Minneapolis, USA, 2007: 17-24
- [11] Ma H, Yang H, Lyu M, King I. Sorec: Social recommendation using probabilistic matrix factorization//Proceedings of the 17th ACM Conference on Information and Knowledge Management. Napa Valley, USA, 2008: 931-940
- [12] Konstantas I, Stathopoulos V, Jose J. On social networks and collaborative recommendation//Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. Boston, USA, 2009: 195-202
- [13] Yuan Q, Chen L, Zhao S. Factorization vs. regularization: Fusing heterogeneous social relationships in top- n recommendation//Proceedings of the 5th ACM Conference on Recommender Systems. Chicago, USA, 2011: 245-252
- [14] Yang X, Steck H, Liu Y. Circle-based recommendation in online social networks//Proceedings of the 18th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. Beijing, China, 2012: 1267-1275
- [15] Noel J, Sanner S, Tran K, et al. New objective functions for social collaborative filtering//Proceedings of the 21st International Conference on World Wide Web. Lyon, France, 2012: 859-868
- [16] Jiang M, Cui P, Liu R, et al. Social contextual recommendation//Proceedings of the 21st ACM International Conference on Information and Knowledge Management. Maui, USA, 2012: 45-54
- [17] Liu Q, Wang C, Xu C. A modified PMF model incorporating implicit item associations//Proceedings of the International Conference on Tools with Artificial Intelligence. Athens, Greece, 2012: 1041-1046
- [18] Salakhutdinov R, Mnih A. Probabilistic matrix factorization//Proceedings of the 2008 International Conference on Machine Learning. Vancouver, Canada, 2008: 880-887
- [19] Yin D, Hong L, Davison Brian D. Structural link analysis and prediction in microblogs//Proceedings of the 20th ACM International Conference on Information and Knowledge Management. Glasgow, UK, 2011: 1163-1168
- [20] Dueck D, Frey B. Probabilistic sparse matrix factorization. University of Toronto, Toronto: Technical Report: PSI-2004-23, 2004
- [21] Lü L, Zhou T. Link prediction in complex networks: A survey. Physical A: Statistical Mechanics and its Applications, 2011, 390(6): 1150-1170
- [22] Lichtenwalter R, Lussier J, Chawla N. New perspectives and methods in link prediction//Proceedings of the 16th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. Washington, USA, 2010: 243-252
- [23] Zhu Yu-Xiao, Lü Lin-Yuan. Evaluation metrics for recommender systems. Journal of University of Electronic Science and Technology of China, 2012, 41(2): 164-175(in Chinese) (朱郁筱, 吕琳媛. 推荐系统评价指标综述. 电子科技大学学报, 2012, 41(2): 164-175, 2012)
- [24] Manning C, Raghavan P, Schütze H. Introduction to Information Retrieval. Cambridge: Cambridge University Press, 2008
- [25] Ricci F, Rokach L, Shapira B. Introduction to Recommender Systems Handbook. New York: Springer US, 2011



GUO Lei, born in 1983. Ph. D. candidate. His research interests include information retrieval, social network and recommender system.

MA Jun, born in 1956, Ph.D., professor, Ph.D. supervisor. His research interests include information retrieval, data mining, parallel computing and natural language processing.

CHEN Zhu-Min, born in 1977, Ph. D., associate professor. His research interests include information retrieval, data mining and social computing.

JIANG Hao-Ran, born in 1986, M. S. Her research interests include grid computing and social computing.

Background

Recommender system as one of the effective information filtering techniques attempts to suggest information items that are likely to interest the users. Contrary to search engine methods, recommendation methods can model users' preferences through their history behaviors and ratings with no explicit intentions. Typically, recommendation methods are based on collaborative filtering, which predicts users' interests by collecting rating information from other similar users or items.

Recently, with the advent of social networks, the exponential growth of user generated information makes social contextual information analysis become important in many applications. And recommendation methods utilizing social networks have become one of the hot research topics. This kind of approach assumes that the decision process of one user is influenced by the friends or trusters that have direct or indirect relations with him/her. Two users who are connected by a trust relation would have similar preferences.

However, most current recommendation methods consider social constraints only from users' perspective, and assume items are independent and identically distributed. This assumption ignores the fact that item connections can be important factors in many scenarios. For example, in friend recommendation scenario, when recommending friends to a user, the target user will probably select the ones having

social relation with his friends.

Motivated by above observations, in our work, we propose to fuse item relations with the rating matrix and social connections using a probabilistic matrix factorization method. The authors model item relations through the shared latent feature space, that is, the item latent feature space in items' relation graph is the same in the rating matrix. Experimental results in real-world dataset show that their approach outperforms state-of-the-art algorithms on the precision and rating error measures.

This work is supported by the National Natural Science Foundation of China (Nos. 61272240, 60970047, 61103151), the Doctoral Fund of Ministry of Education of China (No. 20110131110028), the Natural Science Foundation of Shandong Province (No. ZR2012FM037) and the Excellent Middle-Aged and Youth Scientists of Shandong Province (No. BS2012DX017). These projects aim to study the social media information processing techniques under the application backgrounds of multi-document summarization and social recommendation.

The group is dedicated to doing research on new theories, algorithms and systems for information retrieval, information processing and recommender systems. Related papers have been published in reputable domestic and international journals and conferences.