

信息推荐系统中的朋友关系预测算法设计*

马建威 徐 浩 陈洪辉

(国防科技大学 信息系统工程重点实验室, 湖南 长沙 410073)

摘 要: 伴随着互联网规模的不断扩展, 信息过载问题越来越突出。信息推荐系统被视为解决信息过载问题的最有效方法。然而目前的方法大多数仅考虑用户独立的反馈, 而忽略用户的社会属性对推荐的重要作用, 这对信息推荐系统的性能会造成巨大的影响。为此, 本文提出了基于朋友关系预测的信息推荐算法, 将用户的社会关系预测引入信息推荐过程中, 分别基于用户的拓扑信息及历史交互信息建立用户社会关系的存在性判定及关系类型判定, 并利用线性回归分析方法和逻辑回归分析方法实现了基本特征的融合。最后, 通过在 Epinions 和 Slashdot 真实数据集上的实验证明, 本方法能够有效提高用户社会关系预测的准确性。

关键词: 信息推荐; 朋友关系; 社会网络; 算法设计; MAE(平均绝对误差)

中图分类号: TP393 **文献标志码:** A **文章编号:** 1001-2486(2013)01-0163-06

Friendship prediction in recommender system

MA Jianwei, XU Hao, CHEN Honghui

(1. Science and Technology on Information System Engineering Lab, National University of Defense Technology, Changsha, 410073, China)

Abstract: As the fast development of the Internet scale, "data overload" has become one of the most critical problems in computer network analysis. Recommender system has been regarded as the most effective method to solve the problem. But most of existing methods just consider the independent feedback of users without considering the relationship between users, which will inevitably decrease the performance of recommender system. Thus, a friendship prediction algorithm for recommender system was proposed to predict the relationship between different users. Firstly the topological and historical interaction information was taken as the features to judge the existence and relationship type of links. Then the feature combination process based on linear regression algorithm and logistic regression algorithm was implemented. Finally, the experiments based on the real data sets of Epinions and Slashdot were implemented. The experiment results show that our approaches perform very well in link prediction problem.

Key words: recommender system; friendship relationship; social network; algorithm design; MAE(mean absolute error)

随着云计算技术的大规模运用, 互联网规模的迅速增长在给用户带来海量信息的同时, 也给信息搜索与推荐带来了严峻的挑战。信息过载已成为严重制约信息利用的关键问题, 信息推荐系统被认为是解决信息过载问题最有效的方法, 能够帮助用户完成诸如商品搜索、项目推荐等多项工作, 目前得到最广泛应用的信息推荐算法是协同过滤方法(Collaborative Filtering), 该方法是学术界研究的热点, 在工业界也得到了广泛的商业应用, 如 google、amazon、netflix 等。但传统的协同过滤算法存在诸如冷启动(Cold Start)及数据稀疏(Data Sparsity)等问题, 信息推荐的准确性受到很大影响。为此, 近来一些研究开始将协同过滤与基于内容的过滤相结合, 旨在通过引入一系列

描述用户属性的特征向量来克服上述问题, 从而使推荐性能得到提升。但目前的方法依然主要关注于用户-项目矩阵(User-item Matrix), 缺乏对用户社会关系的分析。

与此同时, 近年来社会网络技术不断发展, 人们开始更多地通过各种社会网络建立彼此之间的联系, 朋友的推荐逐渐成为引导用户使用或购买产品的主要渠道, 两者之间的鸿沟日益形成。迫切需要在信息推荐系统中引入用户社会关系的挖掘与预测, 进而将信息推荐与社会网络技术更好地融合, 实现个性化的推荐。

为此, 本文提出一种信息推荐系统中的朋友关系预测算法, 旨在加强用户的社会关系在信息推荐中的作用, 并根据用户的网络特征及社会属

* 收稿日期: 2012-06-05

基金项目: 国家自然科学基金项目(60903206, 61070216, 71071160); 国家部委资助项目; 国防科技大学研究生创新资助项目(B110502); 湖南省研究生创新资助项目(CX2011024)

作者简介: 马建威(1982—)男, 黑龙江哈尔滨人, 博士研究生, E-mail: majianwei@nudt.edu.cn;

陈洪辉(通信作者)男, 教授, 博士生导师, E-mail: chh0808@gmail.com

性提出用户朋友关系判别的主要特征,进而完成用户的朋友关系预测,为实现信息快速准确的推荐提供技术支持。

本文分别从关系存在性判定和关系类型判定两方面提出了用户朋友关系的预测方法,能够准确预测用户的社会关系;选取大规模真实数据集作为实验对象,进行了详细而细致的分析,挖掘了影响朋友关系判别的关键属性,进而指导实际应用。

1 相关工作

近年来,随着信息过载问题的日益突出,关于信息推荐领域的研究越来越多。与本文相关的研究主要有以下几类:

1.1 协同过滤

协同过滤(Collaborative Filtering)算法是近年来应用最为成功的信息推荐算法,在众多商业网站得到了极为广泛的应用。主要是用来发现用户(User)与产品(Item)之间的相似性,从而推荐可能满足用户需求的产品。主要的方法包括:基于内存的方法^[1,3](Memory-Based Method)与基于模型的方法^[2,4](Model-Based Method)。

一般来说,传统的协同过滤算法通常在用户关系独立的情况下能够比较好地解决推荐的问题,但协同过滤算法普遍存在诸如“冷启动”及“数据稀疏”的问题。由于基于内容的过滤算法^[5]可以较好地克服以上问题,因此最近很多的研究都开始将基于内容的过滤算法与协同过滤算法相结合^[6-7],从而避免两者各自的缺陷。但是当用户关系复杂时,用户之间的关系足以影响推荐相似度的计算,以上两种方法都无法有效地满足用户对推荐精度的要求。

1.2 链路预测

链路预测(Link Prediction)是指利用已知的网络节点及网络结构等信息预测网络中两个节点之间产生链接的可能性^[8]。该问题的研究具有重要的理论和应用价值,正是由于这种重要意义,目前关于链路预测的研究有很多。主要归于以下两大类:基于特征的链路预测方法和基于概率模型的链路预测方法^[9]。近几年,基于特征的链路预测方法得到了广泛的关注,如 Liben-Nowell 等^[10]提出了基于节点拓扑结构的预测方法以及计算节点相似性的方法^[11]等,但目前绝大多数链路预测的研究还仅仅关注链路的正关系,对消极的链路连接研究有所欠缺。

2 朋友关系预测方法

随着社会网络的蓬勃发展,朋友关系的预测作为链路预测的一个关键技术正逐渐成为研究的热点问题。朋友关系的预测是研究利用现有的链路关系去发掘可能存在但尚未标识的链路,这种关系对于用户来讲是隐性的,无法通过显式发现方法去鉴别,但却能够对用户的决策结果产生至关重要的结果。在传统的协同过滤算法中,信息的推荐主要建立在用户与用户的相似性以及产品与产品的相似性度量基础上,通过挖掘用户的历史交互信息完成产品的推荐,但忽略了用户之间可能存在的诸如亲人、朋友以及敌人等关系,从根本上说,这种方法是不完备的。因此,本小节着重介绍朋友关系的预测方法,从而将社会关系引入信息推荐系统,提高推荐的针对性,并进而提升信息推荐系统的性能。

2.1 模型定义

在信息推荐系统中,常用二分图的方法表示用户(user)与项目(item)的关联关系。受到以上观点启发,我们使用图 $G = (V, E)$ 进行模型定义,其中 V 代表节点集合(任一节点 v_i 代表某一用户), E 代表边集合($e = (i, j) \in E_k$ 表示用户 i 与用户 j 的关联关系);每条边的值 $v(i, j)$ 表示这种关联关系的类型(正值代表用户之间的关系是积极的,如朋友关系;而负值则表示存在消极关系,如敌人关系等)。

2.2 关系存在性判定

首先,我们进行朋友关系的存在性判定。这是链路预测的经典问题,已经涌现出众多的研究成果,如基于网络拓扑关系进行预测,基于概率模型进行预测等。然而,在大部分的社会网络运营过程中,暴露给用户的通常只有用户的邻居关系列表。为此,本文基于基本连接矩阵(即只存在用户的社会网络拓扑关系)对用户的社会关系存在性进行判定。我们认为应该包含以下几个主要的特征向量。

- 一个用户的邻居越多,就越可能与其他用户存在联系(Degrees of a node)

结点的度数越高,与其他结点存在链路的可能性越大(即用户越活跃,她的朋友可能就越多)。形式化描述为:

$$\# \text{ of degrees} = \Gamma(v_i)$$

- 共同邻居数量越多的用户之间越可能存在连接(CN, Number of Common Neighbors)

由于共同邻居越多,用户之间存在的相似性就越高,因此对于判断链路存在的可能性而言,共同邻居的数量是一个非常有效的标识方法^[12]。文献[17]中比较了9种局部接近性算法,结果显示最简单的CN算法整体性能最好,AUC(Area Under the Receiver Operating Characteristic Curve)可达到0.9以上。以下是CN的形式化定义:

$$\text{Common Neighbors} = |\Gamma(v_i) \cap \Gamma(v_j)|$$

2.3 关系类型判定

通过捕获用户在社会关系连接中存在的特征可以建立用户社会关系存在性判定的模型。但是在社会网络中,一个用户存在的社会关系既包括积极的(如亲人、朋友等),也包括消极的(如对手、敌人等)。除此之外,同为积极的或消极的关系也存在着程度不同的情况,如好朋友与一般朋友的区别等,这些都将对信息推荐的准确性起到巨大的影响。然而目前的大部分研究包括相当一部分的应用都忽略了消极关联关系的判断以及关联程度的判别,这对整个信息推荐系统的性能都将带来非常不利的影响^[13-15]。为此,我们在关系存在性判定的基础上,将节点度数以及公共邻居两个特征进一步细分,选取能够反映用户关系程度的关键属性作为特征(feature),建立用户社会关系类型的判别方法,以提升信息推荐系统个性化推荐的准确性。

对于判别用户 v_i 与用户 v_j 的社会关系,在得知关系存在的前提下,还需要对用户度数以及共同邻居进行如下划分:

• 用户度数

从社会学角度来说,如果用户 v_i 对大多数人评价都为积极的,那么他对用户 v_j 的评价为积极的可能性就会比较大;相反,如果用户 v_i 对大多数人评价均为负,那么他对用户 v_j 的评价也很可能为负。因此,我们需要选用用户 v_i 的正、负出度作为特征向量。

$$out_+(v_i) \quad out_-(v_i)$$

而对用户 v_j 而言,如果用户 v_j 受到的评价大多为积极的,那么就说明这个人很可能在某一方面有突出能力,因此,他受到来自用户 v_i 的评价为积极的可能性就更大;反之,如果 v_j 收到的评价大多为负,那么 v_i 对他的评价就很可能为负。因此,用户 v_j 的正、负入度也需要作为要计算的特征向量。

$$in_+(v_j) \quad in_-(v_j)$$

与此同时,用户 v_i 对用户 v_j 的评价并不能作

为用户 v_j 对用户 v_i 评价的依据。因此,用户 v_j 的正、负出度以及用户 v_i 的正、负入度也需要作为特征向量进行计算。即:

$$in_+(v_i) \quad in_-(v_i) \quad out_+(v_j) \quad out_-(v_j)$$

• 公共邻居

一般来说,当评价用户 A 与用户 B 的关系时,可以根据需要考虑一跳或两跳范围内的公共邻居^[18]。当数据集规模巨大时,两跳的邻居计算开销较大,且计算思想类似,因此本文只计算一跳距离内的公共邻居,用三角形加以表示的话可以根据与共同邻居的关系不同分为以下4种(图1所示),即:

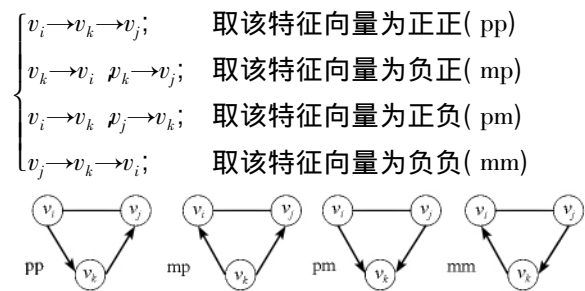


图1 具有一跳距离内公共邻居的4种用户关系

Fig. 1 Four types of relationship

在此基础上,继续考虑每一条边的正负关系表示,则可以将其划分为16种边关系,我们选择每一个子图作为独立的特征向量用以预测 A 与 B 可能存在的关系类型。

至此,我们得到9个度向量,分别为节点度数 $\Gamma(v_i)$,起始节点的正、负出度以及正、负入度($out_+(v_i), out_-(v_i), in_+(v_i), in_-(v_i)$),终止节点的正、负出度以及正、负入度($out_+(v_j), out_-(v_j), in_+(v_j), in_-(v_j)$);以及21个公共邻居向量,分别为($|\Gamma(v_i) \cap \Gamma(v_j)|, pp, mp, pm, mm, pp1, pp2, pp3, pp4, mp1, mp2, mp3, mp4, pm1, pm2, pm3, pm4, mm1, mm2, mm3, mm4$);其中, $\Gamma(v_i)$ 与 $|\Gamma(v_i) \cap \Gamma(v_j)|$ 用以判断关系的存在性,而其他特征向量用以判断关系的正负。

2.4 特征融合

上一小节中,分别引入了关系存在性判别特征(节点度数以及公共邻居数)以及关系类型判别特征(正、负出入度以及 triad 类别),接下来将提出多种方法用以将这些特征整合为单一的评价向量,并对各种方法进行评价,进而为用户提供准确的朋友推荐。

• 多元线性回归分析方法

线性回归(Linear Regression)是数理统计回归分析的一种方法,用来确定两种或两种以上变

量间相互依赖的定量关系,在各种应用中使用非常广泛。文献[14]指出各种预测方法的线性组合可以有效整合资源并取得很好的实验结果。因此,本文采用多元线性回归分析方法对基本特征进行融合计算,形式化描述为:

$$Y = b_0 + b_1 X_1 + b_2 X_2 + \cdots + b_k X_k + u$$

其中 (X_1, X_2, \cdots, X_k) 为观测特征变量值, (b_0, b_1, \cdots, b_n) 为需要估计的参数值, u 为补偿函数。

• 逻辑回归分析

逻辑回归(Logistic Regression)是研究因变量为二分类或多分类观察结果与自变量之间关系的一种多变量分析方法。形式化描述为:

$$Y = \frac{1}{1 + e^{-(b_0 + \sum_{i=1}^n b_i x_i)}}$$

在使用过程中,需要解释变量彼此互不相关。我们采用 Newton-Raphson 方法进行参数估计,以实现基本特征向量的融合,从而提供进行关系判断的唯一变量。

3 实验及结果分析

在实验环节,我们选用了两组大规模真实数据集: Sign Epinions 和 Sign Slashdot 数据集^①。分别对数据集中的节点度数、拓扑结构、正负关系以及公共邻居数量等进行了分析,在此基础上采用线性回归算法和逻辑回归算法对上面提到的特征向量进行了融合分析,旨在发现影响预测准确度的关键特征向量,取得了较好的实验结果。

3.1 数据集描述

• Sign Epinion 数据集

Epinions 是一个比较购物网站,是提供给消费者对所购买的商品进行评论的平台,帮助人们确定购买决策,用户可以发表类似“信任”与“不信任”的评价。本文选用的 Sign Epinions 数据集如表 1 所示,包括 131 828 个节点、841 372 条边以及节点与节点间的正负关系描述,数据稀疏性为 99.992%。

• Sign Slashdot 数据集

Slashdot 是一个与技术相关的新闻网站,允许用户对条目进行“朋友”和“敌人”标记,本文选用的 Sign Slashdot 数据集如表 1 所示,包括 82 144 个节点和 549 202 条边,数据稀疏性为 99.995%。

数据集的详细描述如表 2 所示。

表 1 节点及边的数量

Tab. 1 Nodes and edges

数据集	节点数	边数
Sign Epinions	131 828	841 372
Sign Slashdot	82 144	549 202

表 2 数据集描述

Tab. 2 Data description

Sign Slashdot 数据集描述			
	平均	最小	最大
公共邻居数(以 pp 为例)	2.28	0	205
节点度数	8.23	1	1434
数据稀疏性	99.992%		
正关系比例	77.4%		
Sign Epinions 数据集描述			
公共邻居数(以 pp 为例)	13.11	0	751
节点度数	8.82	1	2070
数据稀疏性	99.995%		
正关系比例	84.5%		

为了测试算法的准确性,我们将数据集中的边划分为训练集 E^{Tr} 和测试集 E^{Te} , $E = E^{Tr} \cup E^{Te}$, $E^{Tr} \cap E^{Te} = \emptyset$ 。我们在数据集中随机抽选 20% 的边作为测试集,用以评价算法的性能,而剩下的 80% 作为训练集,用以对算法进行训练。本实验基于 Pentium(R) D 3.0 GHz 2 GB 内存的硬件环境,使用 Visual Studio 2005 C#, SPSS 13.0 编程语言实现。

3.2 实验结果及分析

本文选用平均绝对误差 MAE (Mean Absolute Error) 作为评价的指标。选择 MAE 作为评价指标的原因在于 MAE 与 RMSE (Root Mean Square Error) 及 ROC (Receiver Operating Characteristic) 有很强的相关性^[16],能够反映数据的真实差异。

$$MAE = \frac{\sum_i |r_i - P(r_i)|}{N}$$

其中 r_i 代表真实的状态值而 $P(r_i)$ 代表预测的状态值。

在实验结果中我们发现,当使用多元线性回归方法作为学习的方法时,可以有效提升预测的准确度,对于 Slashdot 数据集,最好的情况大概有 7% 的提升,而对于 Epinions 数据集则有 5% 的性

① <http://snap.stanford.edu/data>

能提升。另外,在实验过程中,我们发现使用不同的特征向量做预测时,得到的结果会有很大的不同(见表 3),其中最有效的特征向量为 8 种度向量,其次为预测关系类型的 16 种边关系,而同时采用上述 24 种特征向量时所得到的性能最好。至于 pp、mp、pm、mm 四种关系向量,这四类向量的作用主要体现在关系存在性判定上,对于关系类型预测的性能提升起到的作用较小。

表 3 多元线性回归方法

Tab. 3 Linear regression

特征向量	数据集	MAE
$out_+(v_i), out_-(v_i), in_+(v_i)$	Slashdot	0.179
$in_-(v_i), out_+(v_j), out_-(v_j)$		
$in_+(v_j), in_-(v_j)$	Epinions	0.127
	Slashdot	0.222
pp, mp, pm, mm	Epinions	0.155
pp1, pp2, pp3, pp4, mp1, mp2, mp3, mp4, pm1, pm2, pm3, pm4, mm1, mm2, mm3, mm4	Slashdot	0.214
	Epinions	0.139
$out_+(v_i), out_-(v_i), in_+(v_i)$	Slashdot	0.179
$in_-(v_i), out_+(v_j), out_-(v_j)$		
$in_+(v_j), in_-(v_j)$ 和 pp, mp, pm, mm	Epinions	0.127
$out_+(v_i), out_-(v_i), in_+(v_i)$		
$in_-(v_i), out_+(v_j), out_-(v_j)$	Slashdot	0.175
$in_+(v_j), in_-(v_j)$ 和 pp1, pp2, pp3, pp4, mp1, mp2, mp3, mp4, pm1, pm2, pm3, pm4, mm1, mm2, mm3, mm4	Epinions	0.113

而对于逻辑回归,我们采用二项逻辑回归方法,原因在于特征向量数目较多时,很难有效控制多项逻辑回归的进程。实验结果表明:逻辑回归在预测准确度上比多元线性回归方法略好,对于 Slashdot 数据集而言,最高可以获得 10% 的性能提升,而对于 Epinions 数据集,甚至可以将准确度提升至 92.6%。但逻辑回归算法的算法开销较多元线性回归略高,在后续的研究中需要根据应用的实际作一定的权衡。至于特征向量的选择,8 种度向量与 16 种边关系的混合特征向量性能最佳,8 种度向量和 16 种边关系取得的效果次之(见表 4)。

表 4 二项逻辑回归方法

Tab. 4 Logistic regression

特征向量	数据集	MAE
$out_+(v_i), out_-(v_i), in_+(v_i)$	Slashdot	0.163
$in_-(v_i), out_+(v_j), out_-(v_j)$		
$in_+(v_j), in_-(v_j)$	Epinions	0.097
	Slashdot	0.226
pp, mp, pm, mm	Epinions	0.155
pp1, pp2, pp3, pp4, mp1, mp2, mp3, mp4, pm1, pm2, pm3, pm4, mm1, mm2, mm3, mm4	Slashdot	0.189
	Epinions	0.091
$out_+(v_i), out_-(v_i), in_+(v_i)$	Slashdot	0.163
$in_-(v_i), out_+(v_j), out_-(v_j)$		
$in_+(v_j), in_-(v_j)$ 和 pp, mp, pm, mm	Epinions	0.097
$out_+(v_i), out_-(v_i), in_+(v_i)$		
$in_-(v_i), out_+(v_j), out_-(v_j)$	Slashdot	0.149
$in_+(v_j), in_-(v_j)$ 和 pp1, pp2, pp3, pp4, mp1, mp2, mp3, mp4, pm1, pm2, pm3, pm4, mm1, mm2, mm3, mm4	Epinions	0.074

4 结论及下一步工作

本文主要针对目前信息推荐系统缺乏用户社会关系考虑的问题,提出了一种朋友关系预测的方法,该方法主要基于节点间的拓扑关系对用户之间的社会关系存在性进行了判定,而后针对用户的关系类型判别提出了特征向量选取的原则,并通过实验验证得出了用户朋友关系预测过程中的关键特征向量。实验结果表明,该方法能够明显提高用户关系类型的预测准确性。

但是,本文主要是基于用户的节点拓扑进行预测,还有很多需要完善之处,可以结合如群组规模、交互频繁度等特征向量进一步展开研究。下一步的主要工作是认真考虑时间维度对社会关系预测的影响,并建立基于时间的社会关系预测模型。

致谢:感谢 Jure Leskovec 博士提供用于实验验证的数据集,他的研究思路也给了本文很大的启发;同时感谢辛勤工作的审稿专家,他们的评审意见对本文的研究起到了巨大的帮助作用。

参考文献(References)

- [1] Delgado J, Ishii N. Memory-based weighted-majority prediction for recommender systems [C]//Proceedings of SIGIR '99 Workshop on Recommender Systems: Algorithms and Evaluation, 1999.
- [2] Billsus D, Pazzani M. User modeling for adaptive news access. User Modeling and User-adapted Interaction [J]. 2000, 10 (2-3): 147-180.
- [3] Su X Y, Khoshgoftaar T M. A survey of collaborative filtering techniques [J]. Advances in Artificial Intelligence archive, 2009.
- [4] Sarwar B, Karypis G, Konstan J, et al. Item-based collaborative filtering recommendation algorithms [C]//Proceedings of WWW 2001, HongKong, China.
- [5] Raymond J, Roy M L. Content-based book recommendation using learning for text categorization [C]//Proceedings of SIGIR'99 Workshop on Recommender System: Algorithms and Evaluation, Berkeley, CA, August, 1999.
- [6] Yoshii K, Goto M, Komatani K, et al. An efficient hybrid music recommender system using an incrementally trainable probabilistic generative model [J]. IEEE Transactions on Audio Speech and Language Processing, 2008, 16(2): 435-447.
- [7] Girardi R, Marinho L B. A domain model of Web recommender systems based on usage mining and collaborative filtering [J]. Requirements Engineering, 2007, 12(1): 23-40.
- [8] Getoor L, Dieh C P. Link mining: A survey [J]. ACM SIGKDD Explorations Newsletter, 2005.
- [9] Hasan M A, Zaki M J. A survey of link prediction in social networks [R]. Social Network Data Analytics, Springer, 2011.
- [10] Nowell D L, Kleinberg J. The link prediction problem for social networks [J]. Journal of the American Society for Information Science and Technology, 2007, 58(7): 1019-1031.
- [11] Fouss F, Pirotte A, Renders J M, et al. Random-walk computation of similarities between nodes of a graph with application to collaborative recommendation [R]. IEEE Transactions on Knowledge Data and Engineering, 2007.
- [12] 刘宏鲲, 吕琳媛, 周涛. 利用链路预测推断网络演化机制 [J]. 中国科学: 物理学 力学 天文学, 2011, 41(7): 816-823.
LIU Hongkun, LV Linyuan, ZHOU Tao. Uncovering the network evolution mechanism by link prediction [J]. Scientia Sinica Physica, Mechanica & Astronomica, 2011, 41(7): 816-823. (in Chinese)
- [13] Leskovec J, Huttenlocher D, Kleinberg J. Predicting positive and negative links in online social networks [C]//Proceedings of WWW 2010, April 26-30, 2010, Raleigh, North Carolina. USA.
- [14] Jahrer M, Toscher A, Legenstein R. Combining prediction for accurate recommender systems [C]//Proceedings of KDD 2010, July 25-28, 2010, Washington D. C. USA.
- [15] Xiang R J, Neville J, Rogati M. Modeling relationship strength in online social networks [C]//Proceedings of WWW 2010, Raleigh, North Carolina. USA.
- [16] Sarwar B M, Karypis G, Konstan J A, et al. Application of dimensionality reduction in recommender system-a case study [C]//Proceedings of WebKDD 2000 Web Mining for E-Commerce Workshop, 2000.
- [17] Zhou T, LV L Y, Zhang Y C. Predicting missing links via local information [J]. European Physics Journal, 2009(1).
- [18] Jamali M, Haffari G, Ester M. Modeling the temporal dynamics of social rating networks using bidirectional effects of social relations and rating patterns [C]//Proceedings of WWW 2001, HongKong, China.