

## 基于多场景融合的分布式推荐模型

张佳琳

(哈尔滨商业大学 研究生院 黑龙江 哈尔滨 150028)

**摘要:** 个性化推荐系统中普遍存在着信息共享程度低、资源复用不足等问题。针对这些问题,提出基于多场景融合的分布式推荐模型,给出了该模型的组成单元和运行流程,以及对应的场景数据结构。该模型采用分布式的双向刻画的方法,通过多场景融合算法,进行客户特征(需求)与服务场景的互生成,并最终生成推荐列表。仿真实验证明,该模型较之独立节点的推荐模型,在消费娱乐领域,具有较高的客户覆盖度、推荐精度,且占用系统资源较少,具有较高的性价比。

**关键词:** 场景; 分布式推荐; 信息融合; 特征生成; 推荐算法

**中图分类号:** TP393

**文献标志码:** A

### A Distributed Personalized Recommendation Model Based on Multi-scene Fusion

ZHANG Jialin

(Graduate School, Harbin Univ. of Commerce, Harbin 150028, China)

**Abstract:** In order to deal with the lack of information sharing and resource re-utilizations, a novel personalized recommendation model was presented based on multi-scene fusion, and its function units, working flows and the scene data structure were given. The model utilized a distributed bidirectional description method to process scene data, and multi-scene fusion algorithms were used to exchange recommendation information between client characters and service scenes. Simulation results showed that the model has better coverage rates, recommendation precisions and resource consumption rate than the absolute node algorithms.

**Key words:** scene; distributed recommendation; information fusion; recommendation algorithm

目前,个性化推荐系统受到了诸多研究人员的关注,并有众多的算法、模型和系统投入应用,但当前个性化推荐研究普遍遇到了挑战<sup>[1-4]</sup>:首先,随着大数据时代的来临,网络中的数据量爆炸性的增长,而常用计算机的处理能力与人类的信息选择甄别能力进步缓慢,例如,尽管电子商务客户难以从网上现存的百万计的商品中高效的选择到符合自己要求的目标,而单独的电商网站通过推荐算法也很难提供匹配度较高的客户需求商品<sup>[5-6]</sup>。其次是客户可用信息的极大丰富与其自身信息(特征和需求)之间的矛盾<sup>[7-9]</sup>,例如,由于搜索引擎的种类繁多,客户反而难以从中选择出最为有效的工具,并难以发现其中最有价值的信息,此时独立搜索引擎中内嵌的推

荐系统或算法,也无法为其提供搜索引擎之间的信息共享推荐。为应对上述挑战,研究人员提出诸多解决方案<sup>[10-13]</sup>,例如,采用集中式信息中心的方案解决服务方的信息汇总问题,采用信息联盟的方案实现行业推荐依据的共享,采用客户跟踪-服务器信息序列传递方式实现客户需求的采集等。但上述方案仍然存在着信息共享程度低(往往仅限于同行业内若干商家的信息共享),资源复用不充分(推荐列表仅包含单一种类商品的信息)等问题<sup>[14-15]</sup>。

针对上述问题,面向需求最为旺盛的消费与娱乐领域,作者提出一种新型的基于多场景融合的分布式推荐模型 DRSI (distributed personalized recommendation model based on multi-scene fusion)。

收稿日期: 2014-08-20

基金项目: 黑龙江省教育厅科技项目资助(12531161); 黑龙江省博士后资助经费项目(LBH-213126); 黑龙江省自然科学基金面上项目资助(F201424)

作者简介: 张佳琳(1979—),女,副教授,博士,博士后,研究方向: 商务智能; 计算机仿真. E-mail: zhangjialin1979@126.com

http://jsuese.scu.edu.cn

## 1 问题分析与解决方案

DRSI 模型要解决的第 1 个问题: 各个商家(站点)的场景信息, 如何传导和共享? 从目前的研究成果来看, 主要的问题在集中管理的性能瓶颈和移动网络信息共享组织的匮乏上。针对这个问题, 本模型以客户的移动终端作为信息传导和共享的载体, 由客户携带并传播各个商家的场景信息(与客户的自身需求信息一起提交给商家站点), 由商家站点分别进行信息抽取和融合, 并根据融合后的场景结合自身场景进行推荐工作。

DRSI 模型要解决的第 2 个问题: 客户的个性化需求, 如何在商家场景中被满足? 从目前的研究成果来看, 主要问题体现在: 目前的推荐模型, 在客户与商品(服务)信息提取过程各自为战, 导致匹配欠精准。针对这个问题, 本模型采用分布式的双向刻画的方法, 通过一个两阶段算法, 进行需求特征(客户)与服务场景(商家)的互生成, 并生成推荐列表。

为解决上述问题, 在 DRSI 模型中引入了目前电子商务推荐领域的最新工具: 场景(Scene), 通过场景构建数据结构, 以实现(服务器)与客户(客户端)、商家与商家之间进行信息共享。由于推荐工作是以消费群体(客户)作为最重要的研究对象, 因此, 场景数据结构的构建方式如下: 首先设定  $U$  (Unit) 为消费者群体状态(该群体在实际处理中并不以消费群体的支付集合作为最终的群体划分标准, 而根据消费内容作为划分依据)集合; 然后设定  $W$  (will) 为客户的意愿集合; 通过上文中的两项定义, 共同构成  $S$  (Scene) 消费者意愿的定义, 有:  $S \subseteq U \times W \times (0, 1]$ , 由  $(s, p) \in S$  能够进一步描绘出个体消费者的个体场景; 在推荐列表生成时, 个体场景  $s$  (其状态为  $u$ , 而消费意愿为  $w$ ) 中, 内嵌的状态变迁存在对应的转移概率, 并将根据下文中的相关算法生成进行处理, 进行需求特征(客户)与服务场景(商家)的互生成。从目前的实践来看, 该数据结构不但能够较为准确地刻画客户和商家的特征, 而且结构简单高效, 使得后续算法处理较为快速有效, 在不过分占用系统资源的情况下, 能够实现较为精准和全面的推荐, 详见仿真实验与分析部分。

## 2 模型结构与处理流程

模型采用典型的客户服务器结构(C/S: Client/Server), 在处理流程上进行了创新。其模型结构与组成单元, 如图 1 所示, 本模型包括了 3 个组成单元

(虚线绘制的单元并非本模型提供)。

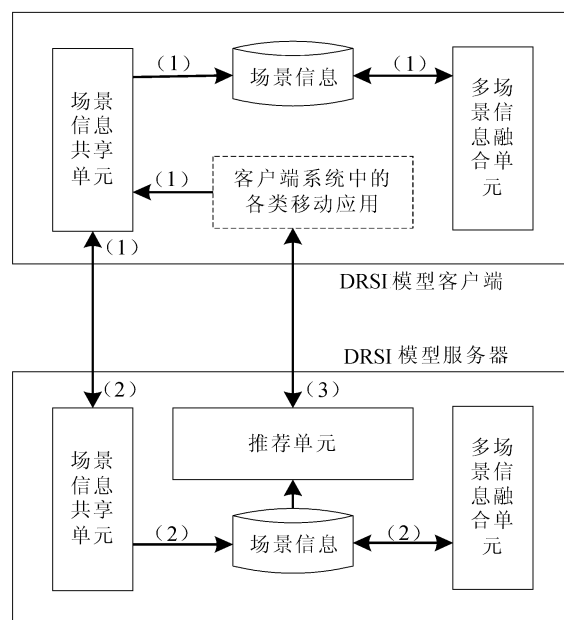


图1 DRSI 模型组成结构

Fig. 1 DRSI model structure

首先是场景信息共享单元。该单元的客户端通过移动终端的各类应用, 跟踪和采集客户的消费信息, 将客户细分为无购买需求、需求性浏览、挑选、购物中、购物后等 5 种状态, 完整地构建客户的消费活动场景, 并填充其中的标签(记录元素)。经处理后的场景信息将发给该单元的当前连接服务器。

其次是多场景融合单元。该单元的客户端通过历史场景信息与实时场景信息(由(1)单元采集), 通过客户行为和商家场景的信息融合, 刻画客户特征与需求。该单元的服务端通过客户提供的实时消费活动场景信息、其他商家场景, 以及客户消费记录与反馈信息, 融合刻画生成自身的商家场景信息。

最后是推荐单元。该单元仅在服务器中运行, 将推荐列表中的内容根据客户端实际场景环境, 以 APP 嵌入广告、网页广告、短信息等形式发布给客户。

如图 1 所示, DRSI 的处理流程分为 3 段:

1) 客户端场景生成阶段。该阶段中, 客户端根据客户的消费/非消费行为活动, 生成其个体的、微观的客户端场景; 该场景能为推荐算法提供客户的品牌喜好、颜色偏好等信息, 并记录有客户经历过的商家场景, 通过对客户端获取的商家场景进行融合, 能够对非消费活动中携带的客户特征与需求信息进行细化, 也为后续的商家场景信息生成奠定了数据基础。通过该阶段工作解决了商家信息共享的问题, 其融合的详细算法参见下文。

2) 商家场景生成阶段。该阶段中,一旦某客户端进入商家网站或与其提供的无线网络连接,此时服务端即为其生成一个局部的视图(商家场景暂储空间);无论客户是否产生消费行为,其特征与需求信息、实时活动,及其经历过的商家场景,都将持续不断的传递给服务器作为推荐的依据,这也是本模型的重大创新之处。

3) 推荐实施阶段。该阶段与商家场景生成阶段有部分并行,当客户端与服务器接驳,并提供了一定的信息后,即实施在线推荐;在客户离线后,仍可以根据其残留信息进行离线推荐。

### 3 关键算法

#### 3.1 服务器关键算法

服务器(商家)中的场景融合算法需要将众多客户提供的局部场景(可以视为客户需求特征的局部视图,也包含客户经历过的商家场景),结合自体描述,通过迭代融合,来刻画关于自身的、较为准确全面的服务场景。

$$J_m(S, V) = \sum_{j=1}^N \sum_{i=1}^c s_{ij} d_{ij}^2 \quad (1)$$

其中:  $S$  为上文中的客户场景(由客户端上传)中的客户状态;  $V$  定义为集合  $\{v_1, v_2, \dots, v_c\}$ , 而  $v_i$  为意愿  $w_i$  集合中的中心矢量; 其自适应的权重值  $m \in (1, \rho)$ ;  $d_{ij}^2 = (x_j - v_i) A (x_j - v_i) A$  为正定矩阵, 当  $A = I$  时, 则有  $d_{ij}$  达到欧式距离, 为  $\|x_j - v_i\|$ 。

式(2)的阈值约束为  $\sum_{i=1}^c s_{ij} = 1$ , 且所有的  $u$  均不为负值; 有上述可以构建场景的无约束函数:

$$F = \sum_{j=1}^N \sum_{i=1}^c s_{ij} d_{ij}^2 - \sum_{j=1}^N \lambda_j \left( \sum_{i=1}^c s_{ij} - 1 \right) \quad (2)$$

当式(2)取极小值时, 必须有:

$$\frac{\partial F}{\partial s_{ij}} = m s_{ij}^{m-1} d_{ij}^2 - \lambda_j = 0 \quad (3)$$

$$\frac{\partial F}{\partial \lambda_j} = - \left( \sum_{i=1}^c s_{ij} - 1 \right) = 0 \quad (4)$$

至此, 通过式(3), 可以生成:

$$s_{ij} = \left( \lambda_j / m d_{ij}^2 \right)^{\frac{1}{m-1}} \quad (5)$$

进一步, 将式(5)代入, 则有:

$$\sum_{i=1}^c s_{ij} = \left( \lambda_j / m \right)^{\frac{1}{m-1}} \sum_{i=1}^c \left( \frac{1}{d_{ij}^2} \right)^{\frac{1}{m-1}} = 1 \quad (6)$$

进行左右替换, 则可得:

$$\left( \lambda_j / m \right)^{\frac{1}{m-1}} = \frac{1}{\sum_{i=1}^c \left( \frac{1}{d_{ij}^2} \right)^{\frac{1}{m-1}}} \quad (7)$$

$$s_{ij} = \frac{1}{\sum_{k=1}^c \left( \frac{d_{ij}}{d_{kj}} \right)^{\frac{2}{m-1}}} \quad (8)$$

由于不能排除  $d_{ij} = 0$  的情况, 因此, 对  $\forall j$  而言, 可以定义有  $I_j$  和  $\bar{I}_j$ :

$$I_j = \{i | d_{ij} = 0\} \quad \bar{I}_j = \{1, 2, \dots, c\} - I_j$$

若  $I_j = \emptyset$ , 则设定:

$$s_{ij} = \frac{1}{\sum_{k=1}^c \left( \frac{d_{ij}}{d_{kj}} \right)^{\frac{2}{m-1}}} \quad (9)$$

反之, 如果  $I_j \neq \emptyset$ , 对于  $\forall j \in \bar{I}_j$ , 则设定  $s_{ij} = 0$ , 并使

$\sum_{i \in I_j} s_{ij} = 1$ 。相似的, 如果  $\frac{\partial J(S, V)}{\partial v_j} = 0$ , 则可设定:

$$\sum_{j=1}^N s_{ij}^m \frac{\partial}{\partial v_i} [x_j - v_i] A [x_j - v_i] = \sum_{j=1}^N s_{ij}^m [-2A(x_j - v_i)] = 0$$

通过上述推导可得:

$$v_i = \sum_{j=1}^N s_{ij}^m x_j / \sum_{j=1}^N s_{ij}^m \quad (10)$$

上述推导可得到最终所需的商家场景(中心场景)的生成公式, 进一步可建立其处理算法流程:

第1步: 首先设置商家内部推荐的种类数量  $c$  ( $2 \leq c < N$ )、计量数  $m$ 、场景矩阵  $A$  和允许误差值  $\varepsilon > 0$ 。

第2步: 生成场景矩阵  $S^{(0)}$ , 其中  $\mu_{ij}$  为矩阵  $S$  中元素, 计数器初始化  $counter = 0$ 。

第3步: 开始处理  $S^{(counter)}$  的  $\{v_i^{(s)}\}$ , 有:

$$v_i^{(s)} = \sum_{j=1}^N s_{ij}^m x_j / \sum_{j=1}^N s_{ij}^m, \quad i = 1, 2, \dots, c$$

第4步: 进一步更新  $S^{(counter)}$ , 从而生成  $S^{(counter+1)}$  ( $j = 1 - N$ )。具体步骤包括: 计算  $I_j$  和  $\bar{I}_j$ ,  $I_j = \{i | d_{ij} = 0\}$  和  $\bar{I}_j = \{1, 2, \dots, c\} - I_j$ ; 进而生成  $x_j$

用于下一步的迭代。此时, 如果  $I_j = \emptyset$ , 则有  $s_{ij} =$

$$\frac{1}{\sum_{k=1}^c \left( \frac{d_{ij}}{d_{kj}} \right)^{\frac{2}{m-1}}}, \text{反之, } s_{ij} = 0, \forall i \in \bar{I}_j, \text{设定: } \sum_{i \in I_j} s_{ij} = 1.$$

第5步: 采用矩阵范数方法, 比较前后矩阵  $S^{(counter)}$  与  $S^{(counter+1)}$ , 当  $\|S^{(counter)} - S^{(counter+1)}\| < \varepsilon$ , 则停止迭代循环; 反之, 计数器  $counter + 1$ , 从第3步开始重新迭代。

#### 3.2 客户端关键算法

DRSI 模型的客户端中的解决方案可以分解为 2 部分主要内容: 第1部分是如何向服务器提供最为精准的自身信息, 已保证推荐的准确性; 第2部分是商家场景信息(例如反馈、评价、浏览活动、关注

热点等),用以进一步刻画推荐过程。综合这2部分的需求,结合场景理论,DRSI客户端的算法可描述如下:首先假设每个客户在经过 $m$ 个商家服务之后产生了对应数量的场景,由于各种主客观因素的干扰,场景信息存在一定的失真;其单个信息的误差可表述为 $X_i = X + \varepsilon_i$ ;即假设客户的第 $i$ 个场景所需信息为 $X_i, i = 1, 2, \dots, m$ 。为了不失一般性,因此设误差 $\varepsilon_i$ 满足一个正态分布 $N(0, \sigma_i^2)$ 。实践中,经常出现突发或畸变信息干扰,因此本算法首先对数值 $X_i$ 实施数据检验,以保护客户的品味等持久性信息;采用的方法为相邻参数差值法,即:

$$|X_{i+1} - X_i| < \varepsilon, |X_3 - X_2| < \varepsilon, \dots, |X_m - X_{m-1}| < \varepsilon \quad (11)$$

其中,阈值 $\varepsilon$ 由商家要求的精度等条件进行配置。当其中 $n$ 条场景信息符合要求时,则对其实施自适应的加权估值;以 $\hat{X}$ 表示融合结果;而本算法的基本思路是在数据的总方差最小的情况下,通过不同商家能提供的场景信息,基于自适应方法生成其优化的加权因子,从而从全局上使得 $\hat{X}$ 最优,由此,设 $n$ 个商家的场景中的某项信息误差方差为: $\sigma_1^2, \sigma_2^2, \dots, \sigma_n^2$ ,真实值为 $X$ ,从 $n$ 个商家的场景中的某项信息值为: $X_1, X_2, \dots, X_n$ ,并且都是对真实信息 $X$ 的无偏估计;至此,如果设加权因子为数组 $W_1, W_2, \dots, W_n$ ,则 $\hat{X}$ 和它们结合后,必须满足下列条件:

$$\hat{X} = \sum_{p=1}^n W_p X_p \quad (12)$$

$$\sum_{p=1}^n W_p = 1 \quad (13)$$

此时,它们的方差可以表述为:

$$\sigma^2 = E[(X - \hat{X})^2] = E\left[\sum_{p=1}^n W_p^2 (X - X_p)^2 + 2 \sum_{p=1}^n \sum_{q=1, q \neq p}^n W_p W_q (X - X_p)(X - X_q)\right] \quad (14)$$

此时,有 $E[(X - X_p)(X - X_q)] = 0$ ,则 $\sigma^2$ 可以表述为:

$$\sigma^2 = E\left[\sum_{p=1}^n W_p^2 (X - X_p)^2\right] = \sum_{p=1}^n W_p^2 \sigma_p^2 \quad (15)$$

由式(15)可以得出结论,总的方差 $\sigma^2$ 是加权因子 $W_p$ 的一个多元2次函数,并存在最小值。如果客户端需要从商家场景中提取尽可能精确的信息,则其总的方差必须小,问题也随之转化为使得加权因子 $W_p$ 的选取符合式(15)中 $\sigma^2$ 达到或逼近最小值的要求。至此,通过多元函数求极值方法,求得当总的方差 $\sigma^2$ 为最小值时,加权因子应为:

$$W_p^* = 1 / \left( \sigma_p^2 \sum_{i=1}^n \frac{1}{\sigma_i^2} \right) \quad (16)$$

式中, $p = 1, 2, \dots, n$ 。

至此,客户端将通过上述算法以及经历过的商家场景,生成自身的个体场景信息(需求及特征),当与新的商家接入时,将其提供给服务器端,以便其通过进一步计算,提供较为精准和全面的推荐服务。

#### 4 仿真实验与结果分析

为了验证DRSI模型的推荐性能,以中国计算机学会CCF提供的数据集为基础信息源,进行了测试数据集构建;最终的采用的数据集中共144名客户(主要是餐饮和服饰消费者)与一个虚拟街区的5个虚拟商家(服务器)的2631次移动信息互动,其中模拟客户端能够记录最近的20个场景,每个虚拟商家则能记录2000个客户的个体场景(仅需存储空间15M)。加实验的主体为某商业大学电子商务专业本科生72名,每名学生模拟2名客户的信息交互活动,并从客户角度作出消费决策;其中,A组实验中5个虚拟商家运行DRSI服务器程序配合推荐算法,B组实验中,虚拟商家独立运行非分布式推荐模型PRs<sup>[7]</sup>。

##### 4.1 宏观性能实验

根据前人研究成果<sup>[4,7]</sup>,试验中选取了客户覆盖率、推荐准确度,以及CPU占用率(系统资源消耗)作为模型性能衡量的指标。

如图2所示,运行DRSI模型的实验组A,不但总体上具有较高的客户覆盖率,而且在单独商家的覆盖度上,也由于分布式结构带来的信息共享程度较高等因素,全面超过了B组中的对应比较对象,且在达到了峰值之后的下降速率低于B组。




图2 模型的客户覆盖度对比

Fig.2 Comparisons of client coverage ratios

如图3所示,运行DRSI模型的实验组A,从总体上看,其推荐准确度较高;并且在单独商家的推荐精度上,全面超过B组中的对应比较对象,其中

60% (3 家) 的商家的平均推荐精度超过了 20% 以上。因此从总体上看,DRSI 模型能够较大幅度地提高推荐系统的准确性。




图 3 模型的推荐准确度

Fig. 3 Comparisons of recommendation accuracies

如图 4 可知,由于 DRSI 模型中相当部分的数据处理工作是由移动终端完成的,甚至推荐信息的共享,也是由移动终端实现信息的传递,因此其消耗的服务器资源较少。从各组的测试记录(每 30 min 进行一次平均系统资源消耗记录)来看,A 组中单次记录的系统资源(CPU 占用率)与 B 组的对应数据相比,最多不超过 10%,甚至有部分 A 组中记录的系统资源消耗量低于 B 组的相应对象,因而整个性能对比面显得相当平缓,无大起伏,这可以解释为 DRSI 模型为较好的信息共享机制和简单高效的算法,避免了推荐列表、客户需求等内容的重复计算,节省了系统资源。




图 4 模型系统资源消耗对比

Fig. 4 System resource consume comparisons

#### 4.2 微观实验过程

图 5 以过程数据截取的方式,展示了第 37 号虚拟客户,在“中餐馆—特产专卖店—小吃店”的消费过程和 2 个推荐系统的微观推荐过程。

从图 5 中可以看出 DRSI 通过场景融合,将多个场景中的特征词融合,用以描述客户的深层需求;而 PRs 仅能依靠客户的消费品名称进行相似度匹配,即使在相同数据量的情况下,疏漏了较多的细节特征,从而导致推荐性能欠佳。其中最代表性和对比性的一条推荐线索描述如下:中餐馆场景中密集出现“香辣”相关特征词,在特产专卖店场景中 DR-

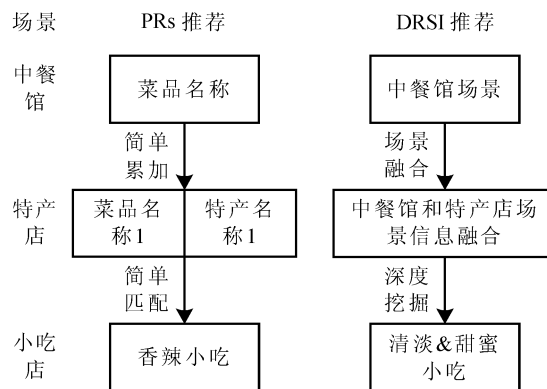


图 5 推荐过程实例

SI 继续向其推荐具有“香辣”特征的商品;进入小吃店场景后由于 DRSI 中的该特征词阈值,因此向其推荐了“清淡”和“甜蜜”特征的小吃,并获成功;PRs 仅仅将购买的商品进行简单的累加(内容上存在重复和隔离),而未能结合场景数据进行处理,重复推荐了相似度高的小吃,反而导致推荐准确率较低。

## 5 结 论

DRSI 分布式推荐模型较之传统的独立节点算法,具有较高的覆盖度和准确度,并且由于该模型的数据处理全分散,推荐处理算法简单易行,因此其占用系统资源有限,具有较高的性价比。但由于该模型的研发初衷是应用于需求最为旺盛的日常消费和娱乐服务领域,因此是否使用于其他领域还有待考证,并适用性改造方案仍需进一步深入研究。未来主要的研究内容包括:单宗大额商品的推荐算法、基于广域行程的客户消费行为跟踪与推荐应用、跨行业跨地域的客户消费预测等。

### 参考文献:

- [1] Lin A J, Hsu C-L, Li E Y. Improving the effectiveness of experiential decisions by recommendation systems [J]. Expert Systems with Applications 2014 41(10): 4904-4914.
- [2] Kolomvatsos K, Anagnostopoulos C, Hadjiefthymiades S. An efficient recommendation system based on the optimal stopping theory [J]. Expert Systems with Applications 2014 41(15): 6796-6806.
- [3] Ying Jiaching, Chen Huansheng, Lin K W, et al. Semantic trajectory-based high utility item recommendation system [J]. Expert Systems with Applications 2014 41(10): 4762-4776.

- [4] Kim Y ,Shim K. TWILITE: A recommendation system for Twitter using a probabilistic model based on latent Dirichlet allocation[J]. Information Systems 2014 ,42( 6) : 59 – 77.
- [5] Kim J W. Scan and click: The uses and gratifications of social recommendation systems[J]. Computers in Human Behavior 2014 ,33( 4) : 184 – 191.
- [6] Ortega F ,Bobadilla J ,Hernando A ,et al. Incorporating group recommendations to recommender systems: Alternatives and performance [J]. Information Processing & Management , 2013 ,49( 4) : 895 – 901.
- [7] Li Dongsheng ,Lyu Qin ,Shang Li ,et al. Item-based top-N recommendation resilient to aggregated information revelation [J]. Knowledge-Based Systems 2014 ,67( 9) : 290 – 304.
- [8] Geva T ,Zahavi J. Empirical evaluation of an automated intraday stock recommendation system incorporating both market data and textual news [J]. Decision Support Systems , 2014 ,57( 1) : 212 – 223.
- [9] Chiang Hsiusen ,Huang Tienchi. User-adapted travel planning system for personalized schedule recommendation [J]. Information Fusion 2014 ,21( 1) : 3 – 17.
- [10] Yuan Xiaofang ,Lee Jihyun ,Kim Sunjoong ,et al. Toward a user-oriented recommendation system for real estate websites [J]. Information Systems 2013 ,38( 2) : 231 – 243.
- [11] Kerebel A ,Cassidy R ,Jordan P ,et al. Farmer perception of suitable conditions for slurry application compared with decision support system recommendations [J]. Agricultural Systems 2013 ,120( 9) : 49 – 60.
- [12] Monfil-Contreras E U ,Alor-Hernández G ,Cortes-Robles G , et al. RESYGEN: A recommendation system generator using domain-based heuristics [J]. Expert Systems with Applications 2013 ,40( 1) : 242 – 256.
- [13] Vera-del-Campo J ,Pegueroles J ,Hernández-Serrano J ,et al. Design of a P2P content recommendation system using affinity networks [J]. Computer Communications ,2013 ,36( 1) : 90 – 104.
- [14] Gemmell J ,Schimoler T ,Mobasher B ,et al. Resource recommendation in social annotation systems: A linear-weighted hybrid approach [J]. Journal of Computer and System Sciences 2012 ,78( 4) : 1160 – 1174.
- [15] Kardan A A ,Ebrahimi M. A novel approach to hybrid recommendation systems based on association rules mining for content recommendation in asynchronous discussion group-original [J]. Information Sciences ,2013 ,219( 10) : 93 – 110.

(编辑 杨 蓓)