

基于服务信誉评价的偏好分析与推荐模型

辛 乐¹, 范玉顺¹⁺, 李 想², 倪亚宇¹

(1. 清华大学 自动化系清华信息科学与技术国家重点实验室, 北京 100084;

2. 中国农业大学 信息与电气工程学院电气工程系, 北京 100083)

摘 要:为了描述用户的个性化偏好需求、优化服务推荐效果,提出基于服务信誉评价的用户偏好分析与服务推荐模型。该模型以服务的多维信誉指标为分析对象,能够兼容服务信誉评价的各种形式,包括数字评分、标签和自然语言评价,并依据模糊多属性决策理论进行自动的用户服务质量偏好的提取及服务推荐。通过对比分析实际服务数据的实验结果,验证了模型的合理性与有效性。

关键词:信誉评价;用户偏好;效用预测;个性化

中图分类号:TP391 **文献标识码:**A

Preference-aware recommendation scheme based on service reputation

XIN Le¹, FAN Yu-shun¹⁺, LI Xiang², NI Ya-yu¹

(1. Tsinghua National Laboratory for Information Science and Technology, Department of Automation,

Tsinghua University, Beijing 100084, China;

2. Department of Electrical Engineering, College of Information and Electrical Engineering,

China Agricultural University, Beijing 100083, China)

Abstract: To describe the preferences of individual users and to optimize the effect of service recommendation, a QoS Preference-aware Recommendation (QPRefR) scheme based on service reputation was proposed. By taking the multi-dimensional reputation indexes of services as the analysis object, various forms of reputation were contained which included numerical rating, labeling and evaluation of natural language. Based on fuzzy multiple attribute decision making theory, automatic extraction of user preferences and recommendation of service were achieved. Theoretical analysis and numerical simulation based on real service evaluation data indicated that the proposed model could present the customer's preference requirements effectively.

Key words: reputation; preference; utility prediction; customization

0 引言

随着面向服务思想^[1]的深化应用,越来越多的企业或个人作为服务提供者,将业务、产品、IT 组件等封装为服务的形式部署于网络之上,并通过统一的接口或规范的交互模式支持服务消费。在该过程

中,服务网络运营平台所发挥的作用包括:①对一种或多种类型的服务进行组织和管理;②支持服务提供者与消费者的交互;③支持服务的检索、调用、评价和组合等。典型的服务网络包括以亚马逊为代表的商品交易平台、以大众点评网为代表的生活服务平台、以 programmableWeb 为代表的应用程序接

收稿日期:2013-11-21;修订日期:2014-04-08。Received 21 Nov. 2013;accepted 08 Apr. 2014.

基金项目:国家自然科学基金资助项目(61033005,61174169);国家科技支撑计划资助项目(2012BAF15G01);高校博士学科点专项科研基金计划资助项目(20120002110034)。**Foundation items:** Project supported by the National Natural Science Foundation, China(No. 61033005,61174169), the National Key Technology R&D Program, China(No. 2012BAF15G01), and the Doctoral Research Fund for Doctoral Program of Higher Education, China(No. 20120002110034).

□(Application Programming Interface, API)管理平台等。

随着服务网络的迅猛发展,信息超载问题开始涌现,并逐渐成为制约服务发现与消费的重大问题。进行个性化的搜索及推荐,既可以帮助用户在海量服务中快速发现所需的服务个体,又能协助网络运营商提升用户体验、推广相关服务,对于解决信息超载问题具有重要的应用意义。推荐系统的核心任务是代替用户对其未知的对象进行评估^[2],该对象可以是多种多样的,例如 Amazon.com 针对商品进行推荐^[3]、MovieLens 对于电影进行推荐^[4]以及 GroupLens 对于新闻文章进行推荐^[5]。

典型的个性化推荐系统主要包括用户数据记录模块、偏好分析模块和推荐算法模块。

(1)用户数据主要包括关注、购买、浏览和评价等行为,以及相应的上下文信息、用户标签、社交网络数据等内容,通过对这些数据的分析,可以建立合适的偏好模型,以描述用户的需求、喜好等信息。根据分析对象的不同,用户分析可以分为基于行为的分析和基于兴趣的分析两类。前者关注用户的访问路径和操作规律,从一系列动作中分析出所属行为模式;后者分析用户的浏览内容,并从中挖掘用户所关注的物品类别等信息。

(2)用户的偏好模型表征方法包括显式与隐式两种:显式用户偏好模型包括基于本体的偏好模型^[6]、偏序偏好模型^[7]、向量空间模型(Vector Space Model, VSM)和基于正反例的模型^[8]等;隐式用户偏好模型间接描述用户的偏好,例如,隐语义模型(Latent Factor Model, LFM)^[9]通过对用户行为数据的聚类进行直接推荐,基于邻域的算法^[10]则依据用户与用户之间、物品与物品之间的相似性来进行推荐,均不显式表征用户的偏好模型。

(3)推荐算法主要可以分为以下几类:

1)基于规则的推荐,由预先定义的规则来分析用户所属类别或潜在需求,实现起来简单方便,但规则很难动态更新,适用范围受到较大限制。

2)协同过滤(Collaborative Filtering, CF),核心理想为面向用户或物品的聚类,根据聚类对象的不同可分为两种:①基于用户的协同过滤算法^[10](UserCF),它假设如果“用户 A 与用户 B 的兴趣度类似,则 A 很可能会喜欢 B 感兴趣的物品”;②基于物品的协同过滤算法^[3](ItemCF),它假设如果“物品甲和物品乙是相似的,则喜欢物品甲的用户很可

能会喜欢物品乙”。协同过滤算法分析的对象多为用户的历史评分信息等数据,但可采用多种方式进行预测,将采用启发式规则进行预测的算法称为基于记忆(memory based)的算法,将采用机器学习模型进行训练和预测的算法称为基于模型(model based)的算法。

3)基于内容(content based)^[11]的推荐,其分析对象为用户已经选择过的物品的内容或属性信息,据此选择类似的物品进行推荐,例如向用户推荐与其购买过的书的作者、主题等类似的其他书籍。基于内容的推荐算法分析基本上针对产品的文本信息,常用技术方法为对用户和产品建立配置文档,记录用户购买(评论、浏览等)或产品被购买(被评论、被浏览等)的记录,并实时更新与分析。

4)基于图模型的推荐^[12],将用户与物品看作图模型中的节点,忽略其内容特征,通过建立用户、物品二部图,分析网络特征并进行物品推荐。

5)混合的推荐算法^[13],融合上述推荐算法,以提升推荐系统的准确度等性能。此外值得关注的推荐算法还包括基于社交网络的推荐^[14]、基于知识的推荐^[15]等。

上文介绍的用户偏好模型与推荐算法已在多个领域取得了较好的效果,在 Web 服务领域,同样有学者做出了相应的研究。对于 Web 服务消费者来说,其对功能性需求的描述往往较为清晰,可用关键字检索、功能树查询等方法,基于统一服务描述发现与集成协议(Universal Description Discovery and Integration, UDDI)等获得备选服务列表,然而多个服务商提供的具有相似功能的服务通常具有不同的非功能属性——服务质量(Quality of Service, QoS)^[16],如执行时间、可信度、价格和安全性等,这些指标在很大程度上影响着用户体验和评价,Xiong^[17]、梁泉^[18]、Nepal^[19]、李祯^[20]和刘晓光^[21]等学者分别建立了相应的用户 QoS 偏好模型,如序关系向量模型、层次分析法(A analytical Hierarchy Process, AHP)模型、自然语言模型等,这些模型的共同特点是需要用户直接参与指定不同的 QoS 指标对于自己的重要性程度。上述研究将服务推荐的关注范围从内容维度扩展到多维的质量维度,对于服务个体的特性分析也更加深入。

然而,随着服务科学的不断发展,服务网络中服务个体的种类已从单一的 Web 服务拓展到多样化的基于网络的业务服务,相比于 Web 服务,业务服

务具有以下特性:①领域的特殊性,对于不同领域的业务服务,难以用统一的、固定的 QoS 维度对服务质量进行描述,且领域的差别易导致用户对服务属性缺乏了解,从而无法用排序、比值和语言描述等形式描述自己的偏好;②环境的复杂性,由于业务服务的交付环境可能包括线上、线下,并往往依赖于其他服务个体或服务网络,相比于单纯 Web 环境的 Web 服务来说,服务质量更加难以保证,服务的宣称 QoS 与用户感知的 QoS 可能存在较大差别,在考虑业务服务的质量时,服务消费者的反馈评价所构成的服务信誉更具有参考意义;③评价数据的异构性与模糊性,Web 服务的 QoS 指标常用确定实数形式给出,而业务服务的信誉指标通常用多种形式进行描述,如评价的分布、标签和自然语言等,无法用固定实数进行描述。上述特征限制了前文所述一系列 Web 服务推荐方法的应用,因此,面向多领域、复杂环境下的业务服务网络,需针对业务服务属性与评价数据的具体特征,研究更加适用的推荐方法。

为解决上述问题,本文提出了基于信誉的用户偏好分析与服务推荐模型(QoS Preference-aware Recommendation Scheme, QPrefR),以基于内容的推荐为基本思想,其主要分析对象为服务的多维信誉评价指标,而非传统算法所关注的物品内容描述,从而提升了服务质量指标的可信度。该模型能够兼容包括数字评分、标签和自然语言评价在内的各种形式的信誉评价。模型以模糊多属性决策理论为基础,进行用户偏好的自动评估及服务推荐,并根据用户的操作行为自动更新其偏好模型,无需用户直接参与指定偏好程度。QPRefR 的步骤包括:①服务质量多维、异构表达方式的归一化;②服务信誉评价的聚合与用户偏好分析;③服务效用预测及推荐。通过对实际服务质量数据的实验和分析,验证了模型的有效性与实用性。

1 用户偏好与行为分析

1.1 偏好特性及表示方式

用户偏好是用户在面对服务时的比较性决策和相关选择,反映了用户的心理感知和理性衡量的结果。在消费者行为理论中,将偏好定义为倾向性次序关系,是一种主观的、个性化的特征,是一种相对的概念。偏好是用户心理非直观的情感和倾向,决定了用户处于一定情境下所采取的选择行为。用户的偏好

建立在对事物认知的情况下,反映了用户的理性分析和判断,因此具有内在的一致性与次序性。

在服务领域中,每个服务个体都可以由一系列质量指标来描述,不同指标对用户具有不同的重要性,则该重要性即权重的集合即为服务消费者的偏好。偏好最直接的获取方式是由用户参与表达,在 Web 服务的 QoS 偏好分析中,常用以下几种形式表达偏好:①语言评价描述,用户将对 QoS 指标的重视程度通过一定格式的语言进行描述,形成评价集合,再对该集合采用自然语言处理、模糊逻辑和本体分析等手段进行处理;②序关系向量,即用户指明对不同 QoS 属性的关注程度的排序,得到各个属性指标的重要性相对顺序关系;③AHP 矩阵^[21],即用户针对 QoS 属性给出两两比较的重要性比值,采用递阶结构进行权重的合成。

但这些方法均需用户参与大量的交互,并给定所需的准确信息。实际服务网络中,由于用户对服务质量的特性、阈值等缺乏了解,无法保证科学、完整地给定所需的排序、比值、语言描述等定义。针对该问题,本文采用无需用户参与的模型对数据进行分析,并参考向量空间模型(Vector Space Model, VSM)进行表示,即一系列 QoS 指标及其权重的二元组 $\{(q_1, c_1), \dots, (q_i, c_i), \dots, (q_m, c_m)\}$ 。

1.2 偏好影响下的行为与效用分析

在服务网络中,用户的需求和偏好影响了用户的一系列操作行为,如浏览、购买和评价等。需要认识到的是,所有的操作行为都可能具有随机性或个体性的特征,随机性是指用户的部分行为可能受到信息的推送方式、服务的动态性、话题的流行性等因素的影响,具有社会性、无偏好的特征;个体性是指用户的某些行为受到用户的知识结构、自身习惯、生活经验、消费历史等因素的影响,表现出较强的个性化特征。在用户行为分析中,往往采取预处理或改进算法的方式进行筛选,抑制随机性行为的影响,重点分析个体性的行为,如改良的 UserCF 算法通过降低两用户间共同感兴趣的热门物品的权重,着重分析其对冷门物品的兴趣相似度,从而提高了相似度计算的准确性。

而效用是指用户在消费服务的过程中及之后所感受的心理体验与实际效果,现代经济学理论将效用看作偏好的一种外在表现,并可用函数形式表征。常用的效用度量表征方法包括基数效用与序数效用,即采用确定的函数形式或效用的排列顺序来表

示水平高低,在现代金融理论中常被表达为指数函数或幂函数的形式。效用可由用户直接表示,如评价、再次购买等,也可由浏览模式等行为隐性表达,通过对这些行为的分析可得出该用户隐含的效用信息。效用的概率分布与用户偏好相关联,若已知用户的效用函数或效用取值,则可通过构建效用函数与偏好的关联关系,提取用户的偏好信息。

本文所关注的数据库主要为配置文件中的历史评价记录,将其视为用户效用的直接表达,通过分析用户的评价信息与服务的综合被评价信息(即信誉),建立偏好模型描述用户需求的个性化特征。

1.3 决策依据与推荐策略

常用的在线推荐系统数据来源包括:①访问日志,包含网址、时间等交互信息;②Cookie记录,站点发送的较详细的数据包;③智能代理,即将用户注册信息和浏览操作发送给远端的服务器进行信息处理与个性化支持;④用户配置文件与物品或服务配置文件,包括用户在服务网络或电子商务网络上操作的记录信息,以及物品或服务被操作的记录信息。

本文的偏好提取算法基于多属性决策理论(Multiple Attribute Decision Making, MADM)^[22]的思想,在进行服务功能约束筛选后,针对有限数量的服务个体进行偏好选择,最终实现排序与推荐。由于偏好本身的内在一致性与次序性体现了用户在决策过程中的个人利益最大化原则,服务推荐即是预测用户对于何类服务将产生最大化的效用的过程,推荐系统的主要决策依据为期望最大化原则,即服务的客观信息满足用户的主观偏好。

本文将 MADM 方法应用于基于多维度信誉的服务推荐中,可以有效避免协同过滤中打分稀疏性、用户数量或物品数量的上升导致运算量大幅增加、推荐系统响应速度非实时等缺点,此外由于考虑了服务的多维信誉指标,增强了推荐的可信度。

2 基于服务信誉的偏好分析方法

2.1 问题描述与算法步骤

本文研究的主要问题是:如何根据用户已评价服务的信誉指标属性以及用户的历史评价信息,分析用户对于该类服务的 QoS 属性偏好,从而依据用户的偏好特性,预测用户对于未知服务个体的效用,进行服务推荐与匹配。

问题精确定义如下: S 表示 N 个服务的集合; Q_k 表示服务 s_k 的 m 个 QoS 指标集合,其元素为 q_{ki} ,用于表征服务 s_k 的第 i 项 QoS 指数,其中, $k \in \{1, 2, \dots, N\}$, $i \in \{1, 2, \dots, m\}$; U 表示用户的集合,服务 s_k 对 u_r 的效用记为 E_{kr} 。令 Ω 为全部二元组 $\{k, r\}$, Λ 为 Ω 中已知的二元组,则基于已有的用户评价信息 $\{E_{kr} | \{k, r\} \in \Lambda\}$,预测未知的效用度量 $\{E_{kr} | \{k, r\} \in \Omega - \Lambda\}$ 。

本文提出的基于服务信誉评价的偏好分析与推荐模型(QPrefR)的基本过程如图 1 所示。其中实线流程表示对用户的评价历史进行偏好提取的过程,虚线流程表示对未知服务进行效用预测和推荐的过程。后文将分别介绍 QPrefR 模型的处理步骤。

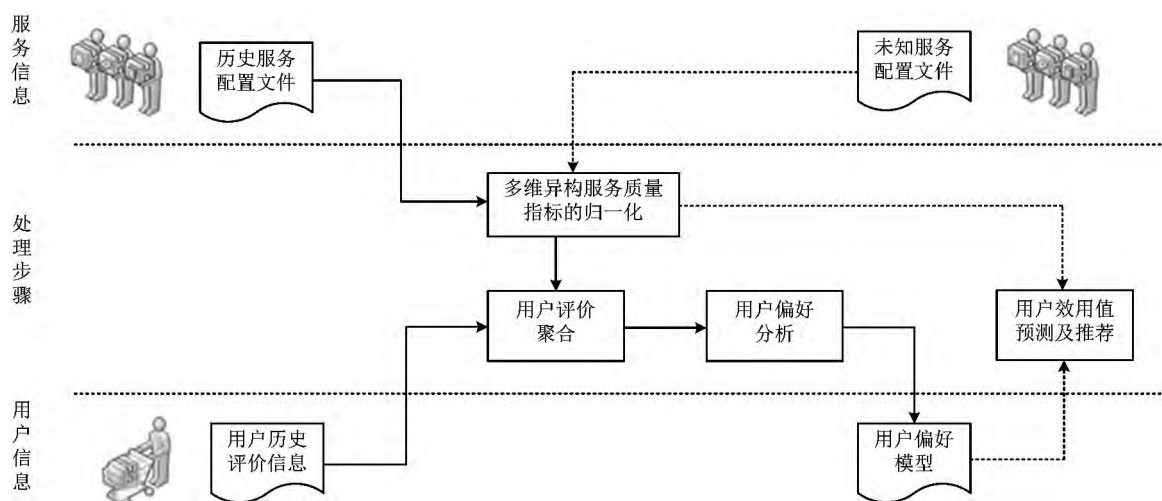


图1 QPrefR算法步骤

2.2 多维异构服务质量指标的归一化模型

2.2.1 服务质量指标的多维异构特征

在服务网络中,由于环境复杂,服务之间或服务提供者与消费者之间的交互存在多种不确定因素,服务的交付效果往往与服务提供者所宣称的 QoS 有差别,如“天猫”平台周年促销时,由于发货量巨大,服务商可能无法实现承诺的发货时限,同时其他因素如服务容量、地理位置等都会影响服务体验,服务的质量指标仅从服务商的简单定义来说是远远不够的。

因此在考虑服务质量的真实表现时,采用信誉即消费者反馈的评分、标签、评语等信息作为度量,这类信息相对于服务商的单方面宣称内容来说更为可信。这些信誉指标通常按照多项质量指标的维度进行划分,而不同平台或不同质量维度之间信誉指标的数据结构也有所不同,为实现对信誉数据的聚合与分析,需要充分考虑其多维、异构的特征,兼容不同的描述方式,分别在相应的维度进行数据汇聚。

目前常用的服务质量指标的评价形式包括:①数字评分,即通过某一区间内的数字描述对服务的满意程度,可针对服务整体进行评价,也可按质量指标进行评价;②标签评价,很多服务平台如大众点评、淘宝等,都提供了消费者指定或添加标签的方法,如评价某餐饮服务的氛围是否适合朋友聚餐、家庭聚会,或是否提供无线上网、免费停车等;③语言评价,即消费者直接用自然语言描述的感受和体验,大多数服务平台将这些自然语言评价直接陈列,少数平台将其处理后提取语义信息,或归纳为不同维度。这些反馈评价完善了服务的定义,也因为众多消费者的参与使得服务的质量属性更为真实可靠,其具体形式总结如表 1 所示。

表 1 服务信誉评价的表达形式

评价形式	维度	取值范围	服务平台	被评价服务类别
数字评分	整体评分	[0,5]	www. amazon. com	各类服务
	描述相符	[0,5]	www. taobao. com	各类服务
	服务态度			
	发货速度			
	描述相符	{-1,0,1}	www. ebay. com	各类服务
	沟通交流			
	发货时间			
	运费和包装费			

续表 1

数字评分	易用程度	[0,5]	www. epinions. com	科技类商品
	技术含量			
	总评分			
	印象			
	表演	[0,10]	movie. mtime. com	电影类服务
	画面			
	故事			
	导演			
	音乐			
	整体			
标签评价	设备设施			
	环境卫生	[0,5]	www. qunar. com	酒店类服务
	地理位置			
	餐饮服务			
	性价比			
自然语言评价				
自然语言评价				
自然语言评价				

2.2.2 服务质量指标归一化模型

目前在基于评价的信誉研究方面,学者们提出了多种模型^[23-24]。Zaki^[25]提出通过聚集反馈评分来衡量服务提供者信誉的分析方法,支持基于信任的服务选择与组合。Yan^[26]提出支持检测与过滤欺诈性不公评价的动态服务选择框架。信誉度量已成为服务选择与管理中的一个关键因素,然而这些信誉信息大多为简单的评分反馈,缺失了标签、语言评价等信息,本文提出多维异构服务质量指标模型,将三种类型的服务质量指标进行统一建模,规范如下:

(1) 数字评分

将服务 s_k 的第 i 项 QoS 指数 q_{ki} 的信誉反馈记为 $rate_{ki}$, 某些 QoS 指标的评分越高, 意味着其表现越佳, 称为正向指标, 如有效性、可靠度和如实描述等, 将其归一化为:

$$q_{ki} = \begin{cases} \frac{rate_{ki} - \min\{rate_i\}}{\max\{rate_i\} - \min\{rate_i\}}, & \max\{rate_i\} - \min\{rate_i\} \neq 0; \\ 1, & \max\{rate_i\} - \min\{rate_i\} = 0. \end{cases} \quad (1)$$

相应地, 某些 QoS 指标项的数值越高, 意味着性能越差, 如响应时间、发货周期等, 称为反向指标:

$$q_{ki} = \begin{cases} \frac{\max\{rate_i\} - rate_{ki}}{\max\{rate_i\} - \min\{rate_i\}}, & \max\{rate_i\} - \min\{rate_i\} \neq 0; \\ 1, & \max\{rate_i\} - \min\{rate_i\} = 0. \end{cases} \quad (2)$$

对于某些窗口类指标, 如预约送货时间等, 将其归一化为:

$$q_{ki} = e^{-\frac{(t-T)^2}{\sigma^2}}, t \in [T_{\min}, T_{\max}]. \quad (3)$$

式中: T 表示最期望的送货时间, 实际送货时间 t 与期望时间的差别越小, 该项指标的评分越高; t 与期望时间的差别越大, 该项指标的评分越低。

将 q_{ki} 按需要划分为 d_i 个区间, 例如: 当 $d_i = 5$ 时, 意味着将其分为 {非常高, 高, 一般, 低, 非常低} 共 5 个级别, 每个级别的上下界分别以 $ub(q_{ij})$ 和 $lb(q_{ij})$ 表示, 则每个 q_{ki} 的取值将属于一个区间, 并由规定的区间上下界决定。

(2) 标签评价

定义服务的第 i 项 QoS 指标为 $q_i = \{tag_1, \dots, tag_j, \dots, tag_{d_i}\}$, 即可由 d_i 个标签来描述, 标签信息来源于服务网络的信誉信息汇总, 即穷举所有对该项 QoS 信息进行描述的标签, 按一定顺序进行排列。对于服务 s_k 的第 i 项 QoS 指数 q_{ki} , 其标签评价可用多元组表示为 $(k, i, tag_j, EvlNo_j)$, 即有 $EvlNo_j$ 个评价认定标签 tag_j 符合该服务的特征。在模糊逻辑下, tag_j 属于 q_{ki} 的隶属度为

$$\mu_{q_{ki}}(tag_j) = \frac{EvlNo_j}{\sum_j EvlNo_j}. \quad (4)$$

(3) 自然语言评价

目前的自然语言分词与解析方法已较为成熟, 如基于字符串匹配、基于理解、基于统计的分词等, 也出现了诸如 ICTCLAS、HTTPCWS 等开源项目, 在这些技术的支持下, 计算机可以正确识别词性、词

义等信息, 一些服务网络开始自动地处理与提取自然语言评语。将语言评价清洗、提炼之后, 可采取标签的方式进行表示, 这时规范的统计框架与式(4)相同。后文将主要以数字评分和标签评价两种形式的信誉信息作为主要内容。

以上是对单个服务个体三种形式信誉信息的规范化表征, 对于服务组合来说, 多位学者^[27-29]已研究并定义了各个流程逻辑或组成类型的服务组合, 特别是 Web 服务组合的 QoS 指标与组合中服务个体的 QoS 指标的函数关系。本文的服务组合选择采用同样的聚集函数 $Q_i(s_1, s_2, \dots, s_n) = f(q_i(s_1), q_i(s_2), \dots, q_i(s_n))$, 不再赘述。

通过上述归一化, 将服务 s_k 的 QoS 指标综合表示为

$$Y_k = [y_{ij}^k]_{m \times n}. \quad (5)$$

式中: $n = \max_i \{d_i\}$ 。 $y_i^k \in \mathbf{R}^{d_i}$, 为 d_i 阶向量, 其阶数与该指标的属性相关, 用行向量的形式表示 s_k 的第 i 项 QoS 指标信息, 其定义如下:

$$y_{ij}^k = \begin{cases} 1, & q_{ki} \text{ 为数字评分, 且} \\ & q_{ki} \in [lb(q_{ij}), ub(q_{ij})]; \\ \mu_{q_{ki}}(tag_j), & q_{ki} \text{ 为标签评价;} \\ 0, & \text{其他。} \end{cases} \quad (6)$$

本节定义了基于信誉反馈信息的多维异构服务质量指标模型, 兼容数字评分、标签评价等形式, 可为后续的用户评价聚合分析提供支持。

2.3 服务评价聚合及用户偏好分析

用正向指标 a_k 表示用户对服务 s_k 的效用度量, 此项指标在用户行为分析中可用多种方式获得, 如获取用户浏览服务页面的时间、用户访问服务的频次、加关注或加入消费清单等, 均可赋予一定的效用指标, 以表征用户的感兴趣程度。最直接的效用度量即为用户对服务的整体评分, 因此将某用户对于服务的评价分数汇聚为

$$\Pi(N) = \sum_{k=1}^N a_k Y_k. \quad (7)$$

特别地, 如果包含用户对服务质量各个维度的评分信息, 则可将评价聚合函数细化为

$$\Pi(N)_i = \sum_{k=1}^N a_{ki} y_i^k. \quad (8)$$

式中 a_{ki} 表示用户对服务 s_k 的指标 q_{ki} 的评分。

在评论聚合的基础上获得用户的偏好度矩阵

$$P(N) = [p_{ij}]_{m \times n}. \quad (9)$$

式中 $p_{ij} = \frac{\Pi(N)_{ij}}{\sum_j \Pi(N)_{ij}} = \frac{\Pi(N)_{ij}}{\sum_K a_k}$, $\sum_{j=1}^n p_{ij} = 1$, 表示

在指标 q_{ki} 中, 用户对 $y_{ij}^k=1$ 的期待偏好度为 p_{ij} 。

用 c_i 表示用户对于质量指标 q_{ki} 的重视程度, 即汇总计算效用度的权重指标, $c_i \in [0, 1]$, $\sum_{i=1}^m c_i = 1$ 。

为求取该项权重指标, 常用方法包括德尔菲法 (delphi method)、AHP 法、Shapley 值法、最优加权法和熵权法等。这些方法各有特点: ① 德尔菲法和 AHP 法均需要专家或用户参与主观地表达重视程度, 虽然采取了密封函评、序数权重等间接方法, 相对地保证了客观公平等原则, 但不可避免地会受到人为因素的影响, 且受到服务平台接口或用户对服务质量指标含义了解情况等限制, 因此不适于做大规模用户数据的分析; ② 最优加权法需求解线性或非线性规划无法保证权重的非负解, 求解计算复杂, 不适合实际应用; ③ Shapley 值法可公平地解决各合作方的收益分配问题, 但需提供总收益随各合作方的加入而增长的过程记录, 由于用户对于各 QoS 指标的评价是无序的, 该方法不适用; ④ 用熵权法分析变量的熵值, 信息熵越高, 不确定性越大, 提供的信息量越低, 因此权重也就越小, 熵值越小, 不确定性越小, 提供的信息量越高, 指标权重就越大, 该方法易于分析, 因此采用熵值法确定指标的权重。

对于随机指标 y_i^k , 其取值为 y_{ij}^k 的概率为 p_{ij} ($j=1, \dots, n$), 则其熵值为

$$H(y_i^k) = E(I(y_i^k)) = k \sum_{j=1}^n p(y_{ij}) I(y_{ij}) = k \sum_{j=1}^n p(y_{ij}) \ln \frac{1}{p(y_{ij})} = -k \sum_{j=1}^n p_{ij} \ln p_{ij}。$$

由于熵值的值域为 $H \in [0, 1]$, 由 $\max\{H(y_i^k)\} = H(p(y_{ij}) = \frac{1}{n}) = -k \sum_{j=1}^n \frac{1}{n} \ln \frac{1}{n} = k \ln n = 1$, 可知 $k = (\ln n)^{-1}$ 。

熵作为无序度的度量, 与权重成反比, 因此用 $1-H(Y_i)$ 作为权重的估量, 归一化后, 即为

$$c_i = \frac{1 - H(Y_i)}{\sum_{i=1}^m (1 - H(Y_i))}, \quad (10)$$

即

$$c_i = \frac{1 + (\ln n)^{-1} \sum_{j=1}^n p_{ij} \ln p_{ij}}{\sum_{i=1}^m (1 + (\ln n)^{-1} \sum_{j=1}^n p_{ij} \ln p_{ij})}。 \quad (11)$$

为避免 $\ln p_{uv} = -\infty$, 若存在 $p_{uv} = 0$, 则令 $p_{uv} =$

$$\frac{1}{10^\lambda} \min_{1 \leq j \leq n, j \neq v} \{p_{uj}\} \text{ 且 } p_{uj} > 0, \lambda \text{ 为非负整数。}$$

在附录中将给出证明, $\lim_{N \rightarrow \infty} P(N) = \lim_{N \rightarrow \infty}$

$\frac{1}{N} \sum_{k=1}^N a_k Y_k = E(a \cdot Y)$ 用于表征用户偏好是可行的, 基于它的用户效用值排序结果收敛于用户的真实偏好所决定的排序结果。

2.4 用户效用预测及服务推荐

根据上述结果, 在提取了用户偏好模型之后, 给定另一服务 s_f 的质量指标 $Y_f = [y_{ij}^f]_{m \times n}$, 其中: $\{y_i\}_{tag}$ 表示以标签形式表述的服务质量指标, $\{y_i\}_{num}$ 表示以数字形式表述的服务质量指标。据此可预测该用户 u_r 对于服务 s_f 的效用度为

$$M_f = \frac{1}{m} \left(\sum_{y_i \in \{y_i\}_{tag}} c_i \sum_{j=1}^n \sigma(y_{ij}^f) p_{ij} + \sum_{y_i \in \{y_i\}_{num}} c_i \sum_{j=1}^n y_{ij}^f \right)。 \quad (12)$$

式中 $\sigma(y_{ij}^f) = \begin{cases} 1 & y_{ij}^f > 0 \\ 0 & y_{ij}^f = 0 \end{cases}$, 表示服务 s_f 在以标签形

式表述的服务质量指标 y_i 中具有 tag_j 的特征, 对于该项特征 y_i 的每个 tag 进行以偏好 p_{ij} 为权重的加权, 即为用户对 y_i 的效用; 若 y_i 以数字形式进行表征, 则已经是经过归一化的正向指标, 可以直接作为用户对 y_i 的效用。对 m 个质量指标进行以 c_i 为权重的加权, 即得到用户对服务的效用预测值。

服务推荐系统中, 在用户定义了对服务的功能要求与质量指标区间性约束之后, 可得到符合用户需求的服务列表, 基于这些服务的质量指标信息, 在用户偏好信息的基础上, 通过 QPrefR 方法比较用户对可用服务的效用值, 按照效用值的最大化原则进行推荐排序, 并在该过程中实时收集用户对服务的效用值, 如浏览时间、关注方式和评分等, 动态更新用户的效用信息, 从而更新其偏好模型, 实现动态、实时推荐。更新方式为:

$$\begin{aligned} & P(N_{eva} + N_k) \\ &= \frac{1}{N_{eva} + N_k} \sum_{k=1}^{N_{eva} + N_k} a_k Y_k \\ &= P(N_{eva}) + \frac{N_k}{N_{eva} + N_k} (P(N_k) - P(N_{eva}))。 \end{aligned}$$

式中: N_k 为新收集到用户评分的服务个数, N_{eva} 为已有该用户评分的服务个数, $P(N_k) =$

$$\frac{1}{N_k} \sum_{k=N_{eva}+1}^{N_{eva}+N_k} a_k Y_k, \text{ 更新后的 } N_{eva} = N_{eva} + N_k。$$

推荐流程如图 2 所示,可根据用户要求不断迭代,直至用户选择到满意的服务为止。

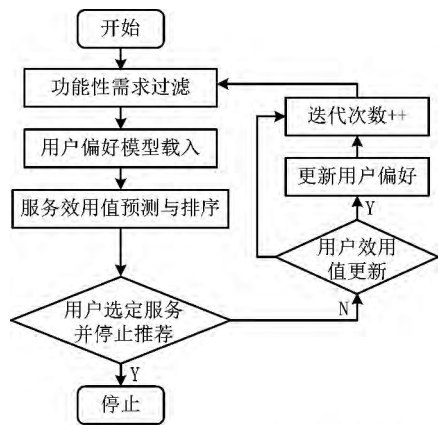


图2 QPrefR的服务效用预测与动态推荐流程

本节给出了 QPrefR 模型的结构与处理模式,通过多维异构服务质量指标的归一化、服务评价聚合、用户偏好分析、用户效用预测及服务推荐,可以实现在服务网络中进行动态、实时的用户偏好分析,并据此进行备选服务的排序与推荐。

3 仿真分析

下面分别采用算例分析、推荐过程仿真、预测误差对比三种方法对 QPrefR 方法的合理性、收敛性与精确性进行验证。

3.1 算例分析

以用户在电子商务网站淘宝网(www.taobao.com)选择服务商家购买衣物为例,对本文提出的 QPrefR 模型进行验证。每个服务在接受众多消费者信誉评分后,将拥有特定的服务质量指标特征。算例分析的主要过程为:设定服务消费者的偏好模型取值,据此取值对服务进行效用评分,再验证基于

这些评价反馈所提取的偏好模型是否与预设的用户偏好信息相一致。

为讨论方便,对服务质量指标体系、用户评价指标进行必要的简化,并描述如下:

定义服务 s_k 的质量指标为 $Q_k = [q_{ki}]_3 = [\text{描述相符}, \text{发货速度}, \text{衣服特色}]$,且每个质量指标的阶数为 $d_i = 3$ 。其中:描述相符和发货速度为数字评分,即 $q_{k1} = q_{k2} = \{high, medium, low\}$,衣服特色为标签评分, $q_{k3} = \{\text{材质好}, \text{尺寸合适}, \text{款式潮}\}$ 。假设 10 个服务的质量指标反馈评分如表 2 所示。则每个服务个体的归一化质量指标可由 2.2 节模型求得。

表 2 算例设置服务质量指标信息

ID	202 099	210 344	804 757	538 524	886 954
描述相符	3.5	3.9	4.9	4.1	4.4
发货速度	4.7	4.7	4.0	4.2	4.4
衣服特色	[0,19,0]	[4,34,0]	[0,7,11]	[0,4,0]	[0,2,0]

ID	580 275	266 271	322 431	221 716	50 758
描述相符	4.9	4.5	4.9	4.8	4.4
发货速度	4.6	4.7	4.0	4.1	4.0
衣服特色	[14,17,0]	[0,150,0]	[5,8,0]	[0,282,0]	[859, 1 134,335]

(1) 设定用户真实偏好为

$$P^* = \begin{bmatrix} 1 & 0 & 0 \\ 0.33 & 0.33 & 0.33 \\ 0.3 & 0.7 & 0 \end{bmatrix},$$

表示用户对描述相符要求为最高,对发货速度不敏感,希望衣服材质好、尺寸合适。由式(10)可知,用户对于 QoS 指标三个维度的重视程度为 $W^* = [0.69, 0, 0.31]$,符合直观判断的偏好顺序。

由用户偏好矩阵与各服务的质量指标可求得用户对各服务的效用值,如表 3 所示。

表 3 用户对服务的效用值

ID	202 099	210 344	804 757	538 524	886 954	580 275	266 271	322 431	221 716	50 758
效用 M	0.22	0.31	0.91	0.22	0.22	1.00	0.22	1.00	0.91	0.31

由于用户评价指标值域为 $[0, 5]$,定义用户评分与效用值成正比, $a = \lceil M \rceil, \lambda = 5$,即为用户根据自身偏好对服务的评分。由 QPrefR 模型,汇聚此用户的信誉评分,并求得其用户偏好为

$$P = \begin{bmatrix} 0.68 & 0.20 & 0.12 \\ 0.36 & 0.28 & 0.36 \\ 0.20 & 0.66 & 0.13 \end{bmatrix}.$$

可得用户对于 QoS 指标三个维度的重视程度为 $W = [0.52, 0.02, 0.46]$,与 W^* 取值相近。

由此可见, QPrefR 模型能够较好地反映用户的真实偏好,由此方法所得的用户偏好与用户实际偏好度相一致。

3.2 推荐过程仿真

为了衡量 QPrefR 模型在复杂服务组合中的适

用性与收敛性,将推荐过程应用于服务组合,如图 3 所示,将服务组合表示为流程图的形式,每个标号的任务节点可由多个备选服务完成,则服务优化选择即为从可行的服务流程中选取最优的路径,如图中的 Path1,按此逻辑组合的服务流程的质量指标最符合用户的期望。为保证并行的任务节点被执行,将其标识为串行的路径,但计算质量指标时仍按照并行结构。




图3 服务组合示例

以图 3 所示流程图为例,每个节点包含 100 个可用的服务,将随机抽取的 1 000 个服务的质量指标赋予所有任务节点的备选服务,采用经典蚁群算法对组合寻优问题进行求解,算法参数为:蚂蚁个数 $M=100$,信息素因子 $\alpha=0.9$,期望启发因子 $\beta=1$,信息素保留比例 $R=0.8$ 。

进行 10 次仿真,每次运行 100 轮蚁群迭代,随机产生用户偏好数据,在 QPrefR 模型下求取用户对于各服务组合的效用值,从而根据寻优所得的效用值进行服务组合推荐。

如图 4 所示,在较少的蚁群迭代周期内,QPrefR 模型即可达到最优水平,模型的全局收敛性较好,即使组合流程较复杂,该方法也能柔性、敏捷地寻找到适合用户偏好的服务组合。




图4 推荐仿真实验寻优结果

3.3 模型性能对比

为保证性能对比实验的真实有效性,选择生活类服务平台大众点评(www.dianping.com)网站的

实际数据作为分析与仿真的对象。选择大众点评网的原因因为它对餐馆、影院等服务商的点评信息丰富、评分维度有所区分,便于求取服务质量指标,且点评用户的信息为非匿名,可检索到用户的点评历史,便于汇聚分析用户的偏好。而淘宝网(www.taobao.com)等网站的大部分点评为匿名信息,不便进行用户分析;亚马逊(www.amazon.cn)与京东(www.jd.com)等电子商务平台未区分信誉评分维度,服务质量信息常集中在整体评价的维度。

基于 JDK6.0 环境与 MySQL 数据库编写爬虫程序 SDataDrawler 进行数据采集,共采集到北京地区 3 755 个服务的质量指标信息、4 605 篇用户评分与评语数据。基于此将 QPrefR 模型与以下两种模型做预测精度对比分析:

(1)AFM 模型^[16] 与大多数研究 QoS 指标加权的方法相同,将各项指标的权重视为相等,没有对服务质量指标的重要度进行区分。

(2)SF 模型^[30] 将不同性质的 QoS 指标权重新进行区分,以 10^β 进行标注,其中 β 为重要性递增排列时该项指标的序号,对服务质量指标的重要度进行初步区分。

误差评定指标为平均绝对误差(MAE)与均方根误差(RMSE),其定义为

$$MAE = \frac{\sum_{rk} |\hat{M}_{rk} - M_{rk}|}{N}; \quad (13)$$

$$RMSE = \sqrt{\frac{\sum_{rk} (\hat{M}_{rk} - M_{rk})^2}{N}}. \quad (14)$$

式中: \hat{M}_{rk} 为根据用户评价历史预测其对服务 s_k 的效用值; M_{rk} 为真实效用值; N 为预测的总数量。

为分析数据密度对预测结果的影响,将评价数据随机分为两部分:一部分用于提取用户偏好信息,另一部分用于检验预测结果的准确度。其中,将已知评价值的数据密度从 10% 逐渐增长至 65%,AFM,SF 和 QPrefR 三个模型的预测精度如表 4、图 5 和图 6 所示。

在表 4 中,用黑体字标明了取得的最小 MAE 或 RMSE 值,即最精确预测的结果,从数据可以看出,三种模型中,QPrefR 方法由于分析了用户的历史效用信息,提取了用户的偏好,并将偏好信息在效用预测阶段进行了考虑,具有更高的精确度。由此可见,挖掘用户的潜在偏好需求,对于精确预测用户评分、进行服务选择与推荐具有现实意义。

表 4 性能对比(更小的 MAE 或 RMSE 意味着更好的性能)

数据密度		10	15	20	25	30	35	40	45	50	55	60	65
MAE	AFM	0.980 7	0.841 3	0.838 3	0.836 6	0.816 9	0.856 0	0.798 2	0.798 2	0.711 6	0.660 7	0.601 7	0.980 7
	SF	1.027 8	0.891 3	0.815 1	0.846 4	0.763 3	0.817 8	0.753 5	0.753 5	0.774 1	0.700 8	0.727 6	1.027 8
	QPrefR	0.731 7	0.701 9	0.658 0	0.650 8	0.641 0	0.633 9	0.623 2	0.623 2	0.557 1	0.537 5	0.533 0	0.731 7
RMSE	AFM	1.156 7	1.037 5	1.026 7	1.033 0	1.030 3	1.060 7	1.02 5	0.987 5	0.912 5	0.855 3	0.802 6	1.156 7
	SF	1.240 3	1.116 3	1.054 4	1.086 6	0.988 3	1.017 8	0.961 6	0.970 5	0.987 5	0.909 8	0.942 8	1.240 3
	QPrefR	0.942 3	0.900 0	0.866 9	0.871 4	0.866 0	0.833 0	0.833 0	0.808 0	0.748 2	0.733 0	0.728 5	0.942 3




图5 模型性能MAE对比




图6 模型RMSE对比

4 结束语

识别用户潜在需求,帮助用户快速寻找到符合其偏好的服务,是服务网络运营中十分重要的环节。本文提出了基于服务信誉的偏好分析与推荐模型 QPrefR,它是可兼容数字评分、标签评价、自然语言评价的多维异构服务质量指标模型;以用户的历史评价记录为分析对象,提取用户的 QoS 偏好模型,实现自动、定量地提取用户对各质量指标维度的偏好权重,对备选服务进行效用预测,实现个性化服务排序与推荐。在服务推荐系统中应用多属性决策方法分析用户的偏好信息,可以有效避免协同过滤中

打分稀疏性、用户数量或物品数量的上升导致运算量大幅增加的缺点,提升系统的响应速度,且考虑了服务的多维信誉指标,从而增强了推荐的可信度。最后,通过算例分析与真实数据预测精度对比实验,验证了模型的合理性、收敛性与精确性。

参考文献:

[1] ZHANG Jianliang, FAN Yushun. Service-oriented enterprise and business ecosystem[J]. Computer Integrated Manufacturing Systems,2010,16(8):1751-1759(in Chinese). [张建良,范玉顺. 面向服务的企业与业务生态系统[J]. 计算机集成制造系统,2010,16(8):1751-1759.]

[2] LIU Jianguo, ZHOU Tao, WANG Binghong. Progress of the personlaized recommendation systems[J]. Progress in Natural Science,2009(1):1-15(in Chinese). [刘建国,周涛,汪秉宏. 个性化推荐系统的研究进展[J]. 自然科学进展,2009(1):1-15.]

[3] LINDEN G, SMITH B, YORK J. Amazon. com recommendations: item-to-item collaborative filtering[J]. IEEE Internet Computing, 2003,7(1):76-80.

[4] MILLER B N, ALBERT I, LAM S K, et al. Movie lens unplugged: experiences with an occasionally connected recommender system[C]//Proceedings of ACM 2003 International Conference on Intelligent User Interfaces. New York, N. Y., USA: ACM Press,2003:263-266.

[5] KONSTAN J A, MILLER B N, MALTZ D, et al. GroupLens: applying collaborative filtering to usenet news[J]. Communications of the ACM,1997,40(3):77-87.

[6] YANG Yan, LI Jianzhong, GAO Hong. Ontology-based preference model in digital library[J]. Journal of Software,2005,16(12):2080-2088(in Chinese). [杨艳,李建中,高宏. 数字图书馆系统中基于 Ontology 的用户偏好模型[J]. 软件学报,2005,16(12):2080-2088.]

[7] KIEBLING W. Foundations of preferences in database systems[C]//Proceedings of the 28th International Conference on Very Large Data Bases. New York, N. Y., USA: ACM,2002:311-322.

[8] WEBB G I, PAZZANI M J, BILLSUS D. Machine learning for user modeling[J]. User Modeling and User-Adapted Inter-

- action, 2001, 11(1/2):19-29.
- [9] KOREN Y, BELL R, VOLINSKY C. Matrix factorization techniques for recommender systems[J]. Computer, 2009, 42(8):30-37.
- [10] JEONG B, LEE J, CHO H. User credit-based collaborative filtering[J]. Expert Systems with Applications, 2009, 36(3):7309-7312.
- [11] PARK H, YOO J, CHO S. A context-aware music recommendation system using fuzzy bayesian networks with utility theory[M]//Fuzzy Systems and Knowledge Discovery. Berlin, Germany: Springer-Verlag, 2006:970-979.
- [12] HUANG Z, CHEN H, ZENG D. Applying associative retrieval techniques to alleviate the sparsity problem in collaborative filtering[J]. ACM Transactions on Information Systems, 2004, 22(1):116-142.
- [13] LEE J, OLAFSSON S. Two-way cooperative prediction for collaborative filtering recommendations[J]. Expert Systems with Applications, 2009, 36(3):5353-5361.
- [14] WEI C, KHOURY R, FONG S. Web 2.0 Recommendation service by multi-collaborative filtering trust network algorithm[J]. Information Systems Frontiers, 2013, 15(4):533-551.
- [15] VELASQUEZ J D, PALADE V. Building a knowledge base for implementing a Web-based computerized recommendation system[J]. International Journal on Artificial Intelligence Tools, 2007, 16(5):793-828.
- [16] HUANG A, LAN C W, YANG S. An optimal QoS-based Web service selection scheme[J]. Information Sciences, 2009, 179(19):3309-3322.
- [17] XIONG R, LUO J, SONG A, et al. QoS preference-aware replica selection strategy using map reduce-based PGA in data grids[C]//Proceedings of International Conference on Parallel Processing ICPP. Wahsington, D. C., USA: IEEE, 2011:394-403.
- [18] LIANG Quan, WANG Yuanzhuo. Treatment strategies of QoS preference information based on service on demand[J]. Information and Control, 2009, 38(6):698-702(in Chinese). [梁 泉, 王元卓. 基于按需服务的用户 QoS 偏好信息的处理策略[J]. 信息与控制, 2009, 38(6):698-702.]
- [19] NEPAL S, SHERCHAN W, HUNKLINGER J, et al. A fuzzy trust management framework for service Web[C]//Proceedings of the 2010 IEEE International Conference on Web Services (ICWS). Washington, D. C., USA: IEEE, 2010:321-328.
- [20] LI Zhen, YANG Fangchun, SU Sen. Fuzzy multi-attribute decision making-based algorithm for semantic Web service composition[J]. Journal of Software, 2009, 20(3):583-596(in Chinese). [李 祯, 杨放春, 苏 森. 基于模糊多属性决策理论的语义 Web 服务组合算法[J]. 软件学报, 2009, 20(3):583-596.]
- [21] LIU Xiaoguang, JIN Ye. Research on non-functional conditions-based Web services selection in Web services automation[J]. Computer Integrated Manufacturing Systems, 2006, 12(2):297-301(in Chinese). [刘晓光, 金 烨. 网络服务自动化中基于非功能性条件约束的服务选择研究[J]. 计算机集成制造系统, 2006, 12(2):297-301.]
- [22] FAN Z, MA J, ZHANG Q. An approach to multiple attribute decision making based on fuzzy preference information on alternatives[J]. Fuzzy Sets and Systems, 2002, 131(1):101-106.
- [23] CHANG G. A reputation model of Web services[C]//Proceedings of the 3rd IEEE International Conference on Communication Software and Networks. Washington, D. C., USA: IEEE, 2011:1-3.
- [24] RUOHOMAA S, KUTVONEN L, KOUTROULI E. Reputation management survey[C]//Proceedings of the 2nd International Conference on Availability, Reliability and Security. DOI:10.1109/ARES.2007.123.
- [25] MALIK Z, BOUGUETTAYA A. RATEWeb: reputation assessment for trust establishment among Web services[J]. VLDB Journal, 2009, 18(4):885-911.
- [26] YAN S, ZHENG X, CHEN D. Dynamic service selection with reputation management[C]//Proceedings of 2010 International Conference on Service Sciences. DOI:10.1109/ICSS.2010.67.
- [27] CANFORA G, DI PENTA M, ESPOSITO R, et al. A framework for QoS-aware binding and re-binding of composite Web services[J]. Journal of Systems and Software, 2008, 81(10):1754-1769.
- [28] ZENG L, BENATALLAH B, NGU A H H, et al. QoS-aware middleware for Web services composition[J]. IEEE Transactions on Software Engineering, 2004, 30(5):311-327.
- [29] LIU Weining, LIU Bo, SUN Dihua. Study on multi-task oriented service composition in cloud manufacturing[J]. Computer Integrated Manufacturing Systems, 2013(1):199-209(in Chinese). [刘卫宁, 刘 波, 孙棣华. 面向多任务的制造云服务组合研究[J]. 计算机集成制造系统, 2013(1):199-209.]
- [30] LI Sufen, FAN Yushun. A two-layer service selection model based on distance relations[J]. Journal of Tsinghua University: Science and Technology, 2011, 51(3):293-297(in Chinese). [李素粉, 范玉顺. 基于地理位置关联的两层服务选择模型[J]. 清华大学学报: 自然科学版, 2011, 51(3):293-297.]

作者简介:

辛 乐(1987—),女,河北邢台人,博士研究生,研究方向:服务网络、信誉模型, E-mail: xin-l09@mails. tsinghua. edu. cn;

+ 范玉顺(1962—),男,江苏扬州人,教授,博士,博士生导师,研究方向:企业信息化战略管理、服务科学、企业建模与系统集成、工作流管理等,通信作者, E-mail: fanys@tsinghua. edu. cn;

李 想(1983—),男,广东广州人,讲师,博士,研究方向:复杂服务网络、实时复杂事件检测等;

倪亚宇(1988—),男,四川乐至人,博士研究生,研究方向:服务计算。

附录 1:

求证 若服务的 QoS 指标间相互独立且同分布,则当 $N \rightarrow \infty$ 时,由 $P(N)$ 计算所得的用户效用值排序结果与用户真实偏好决定的排序结果一致。

证明 首先,由 $p_{ij} = \frac{1}{\sum_K a_k} \cdot \sum_{k=1}^N a_k Y_k$ 可知, a_k

为随机变量, Y_k 为随机矩阵, $a_k Y_k$ 有界,由大数定理, $\lim_{N \rightarrow \infty} P(N)$ 收敛的概率为 1。

将用户的真实偏好记为 $P^* = [p_{ij}^*]_{m \times n}$, 用户对于服务的评价与其真实效用值 M^* 成正比,即 $a = \lambda M^* = \frac{\lambda}{m} \sum_{i=1}^m c_i \sum_{j=1}^n y_{ij} p_{ij}^*$, $0 < \lambda \leq 1$, 则代入求取 $P(N)$ 的公式可得:

$$\begin{aligned} P(N) &= \frac{1}{\sum_K a_k} \sum_{k=1}^N a_k Y_k \\ &= \frac{1}{\sum_K a_k} \sum_{k=1}^N \left(\frac{\lambda}{m} \sum_{j=1}^n \sum_{i=1}^m c_i y_{ij}^{(k)} p_{ij}^* \right) Y_k \\ &= \frac{\lambda}{m} \sum_{j=1}^n \sum_{i=1}^m c_i p_{ij}^* \frac{1}{\sum_K a_k} \sum_{k=1}^N y_{ij}^{(k)} y_{uv}^{(k)}. \end{aligned}$$

当 $N \rightarrow \infty$ 时,令 $\sum_K a_k = N \cdot \overline{a_k}$, 有

$$\begin{aligned} &\lim_{N \rightarrow \infty} p_{uv}(N) \\ &= \frac{\lambda}{m \cdot \overline{a_k}} \sum_{j=1}^n \sum_{i=1}^m c_i p_{ij}^* \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N y_{ij}^{(k)} y_{uv}^{(k)} \end{aligned}$$

$$\begin{aligned} &= \frac{\lambda}{m \overline{a_k}} \sum_{j=1}^n \sum_{i=1}^m c_i p_{ij}^* E(y_{ij} \cdot y_{uv}) \\ &= \frac{\lambda}{m \overline{a_k}} \sum_{j \neq v \text{ 且 } i \neq u} c_i p_{ij}^* E(y_{ij} \cdot y_{uv}) + \frac{\lambda}{m \overline{a_k}} c_u p_{uv}^* E(y_{uv}^2) \\ &= \frac{\lambda}{m \overline{a_k}} \sum_{j \neq v \text{ 且 } i \neq u} c_i p_{ij}^* E(y_{ij}) \cdot E(y_{uv}) + \frac{\lambda}{m \overline{a_k}} c_u p_{uv}^* E(y_{uv}^2) \\ &= \frac{\lambda}{m \overline{a_k}} \sum_{j=1}^n \sum_{i=1}^m c_i p_{ij}^* E(y_{ij}) \cdot E(y_{uv}) - \frac{\lambda}{m \overline{a_k}} c_u p_{uv}^* E^2(y_{uv}) + \frac{\lambda}{m \overline{a_k}} c_u p_{uv}^* E(y_{uv}^2) \\ &= \frac{\lambda}{m \overline{a_k}} E(y_{uv}) \sum_{j=1}^n \sum_{i=1}^m c_i p_{ij}^* E(y_{ij}) + \frac{\lambda}{m \overline{a_k}} c_u p_{uv}^* D(y_{uv}). \end{aligned}$$

由于 y_{uv} 是同分布的随机变量,记 $E(y_{uv}) = E(y)$, $D(y_{uv}) = D(y)$, 上式可简化为

$$\lim_{N \rightarrow \infty} p_{uv, N} = \alpha p_{uv}^* + \beta.$$

式中: $\alpha = \frac{\lambda}{m \overline{a_k}} c_u D(y_{uv}) > 0$, $\beta = \frac{\lambda}{m \overline{a_k}} E^2(y) \sum_{j=1}^n \sum_{i=1}^m c_i p_{ij}^*$ 。

从而得到 $\lim_{N \rightarrow \infty} P(N) = \alpha P^* + \beta$, 即随着 $N \rightarrow \infty$, $P(N)$ 与 P^* 成线性关系, 即由 $P(N)$ 所决定的效用度排序的结果趋向于 P^* 的结果, 可以反映用户的真实偏好情况, 模型是有效并收敛的。证毕。